

Guilherme Henrique De Nardi

**Conectividade e Spillovers de Volatilidade no
Sistema Bancário Brasileiro: Uma Análise de Redes
via Diebold-Yilmaz**

Osasco

2026

Guilherme Henrique De Nardi

**Conectividade e Spillovers de Volatilidade no Sistema Bancário
Brasileiro: Uma Análise de Redes via Diebold-Yilmaz**

Projeto de pesquisa submetido como parte da
avaliação da UC MONOGRAFIA I, do curso de
graduação em Ciências Econômicas da Univer-
sidade Federal de São Paulo - Campus Osasco,
sob orientação do Prof. Dr. Diego Ferreira.

Universidade Federal de São Paulo
Escola Paulista de Política, Economia e Negócios

Orientador: Diego Ferreira

Osasco
2026

Sumário

1	INTRODUÇÃO	3
2	REVISÃO BIBLIOGRÁFICA	5
3	METODOLOGIA	11
3.1	Base de Dados	11
3.2	Topologia de Redes via Diebold-Yilmaz	20
3.3	Visualização de Redes	25
4	RESULTADOS	26
	Referências	27

1 Introdução

O sistema bancário brasileiro enfrentou, entre 2017 e 2026, um período marcado por choques de naturezas distintas como uma pandemia global, o ciclo de aperto monetário do pós-pandemia, e episódios de instabilidade idiossincrática como o caso Americanas. Esses episódios oferecem um cenário propício para investigar como o risco se propaga entre instituições financeiras, e se essa propagação muda de intensidade e direção conforme a natureza do choque. Risco sistêmico refere-se à possibilidade de que o colapso ou fragilização de uma instituição se propague para o restante do sistema, ameaçando sua estabilidade como um todo. A literatura sobre redes financeiras estabelece que a arquitetura de interconexão que confere resiliência ao sistema em momentos de normalidade pode se converter em um mecanismo de amplificação dependendo da magnitude de um choque (Acemoglu; Ozdaglar; Tahbaz-Salehi, 2015). Compreender essa dinâmica, não apenas a magnitude mas também a evolução ao longo do tempo, é relevante tanto para a literatura quanto para a formulação de política macroprudencial.

Mensurar a propagação de forma contínua e baseada em dados públicos é o objetivo central deste trabalho, que investiga a rede de spillovers de volatilidade entre os principais bancos brasileiros ao longo do recorte 2017-2026. A pergunta que orienta a pesquisa é como a estrutura da rede entre essas instituições evolui ao longo do tempo e reage a eventos macroeconômicos e idiossincráticos. A investigação busca não apenas identificar a existência de interdependência entre as instituições, mas compreender mudanças na topologia da rede com variações no grau de conectividade e na importância relativa de cada instituição em diferentes contextos econômicos.

A hipótese do trabalho é de que a intensidade de spillovers se eleva em períodos identificáveis instabilidade financeira, como a pandemia do COVID-19, o ciclo de aperto monetário e episódios idiossincráticos, refletindo maior interconectividade e potencial de propagações de choques, em linha com a dinâmica prevista pela literatura teórica de redes financeiras (Acemoglu; Ozdaglar; Tahbaz-Salehi, 2015; Allen; Gale, 2000)

A abordagem adotada baseia-se no modelo de Diebold e Yilmaz (2009, 2012, 2014), que utiliza um vetor autorregressivo (VAR) e a decomposição generalizada da variância dos erros de previsão (GFEVD) para mensurar a interdependência entre variáveis, construindo uma matriz de spillovers interpretável como a matriz de adjacência de uma rede complexa dirigida e ponderada. A variável-alvo é a volatilidade, não os retornos, estimada por um estimador de amplitude (range-based) que combina o componente de Rogers e Satchell (1991), independente de tendência intradiária, com um termo de retorno overnight, capturando o fato de que decisões do Comitê de Política Monetária e resultados trimestrais são divulgados após o fechamento do pregão. A amostra é estratificada por tipo de controle de capital, porte e modelo de negócio, e organizada em dois painéis aninhados: um painel principal, com maior alcance temporal, e um painel de extensão que incorpora o Banco Pan, cuja relação de controle com o BTG Pactual permite testar diretamente se o vínculo societário entre instituições se traduz em maior

comovimento de volatilidade.

Embora a metodologia de Diebold-Yilmaz tenha sido amplamente aplicada a mercados financeiros internacionais e a índices de ações de economias emergentes, sua aplicação ao nível de instituições bancárias individuais no Brasil permanece escassa. Os estudos brasileiros de risco sistêmico predominantemente dependem de dados de balanço ou de exposições interbancárias sigilosas, mantidas pelo Banco Central e inacessíveis à comunidade científica, o que compromete a comparabilidade dos resultados e restringe análises em escala ampla e frequência elevada. Este trabalho preenche essa lacuna em três frentes. Primeiro, estratifica a amostra por tipo de controle, modelo de negócio e porte, tornando a heterogeneidade institucional do sistema bancário brasileiro explícita na análise de spillovers. Segundo, compara explicitamente o ranking de importância sistêmica derivado dos spillovers com a segmentação prudencial do Banco Central do Brasil, testando se uma metodologia baseada inteiramente em dados públicos de mercado é capaz de aproximar a classificação regulatória das instituições consideradas sistemicamente relevantes. Terceiro, incorpora métricas de teoria de redes além dos índices direcionais de primeira ordem propostos por Diebold e Yilmaz como centralidade de autovetor e PageRank, cuja formulação recursiva captura a posição estrutural de cada banco na topologia de contágio e testa a hipótese de vínculo societário por meio de uma regressão em painel de pares com efeitos fixos, abordagem mais robusta do que comparações agregadas por categoria nominal de controle.

O restante do trabalho está organizado em três capítulos. O Capítulo 2 revisa a literatura sobre risco sistêmico, conectividade em redes financeiras e a evolução metodológica do framework de Diebold-Yilmaz, situando as contribuições deste trabalho no debate. O Capítulo 3 detalha a metodologia: a base de dados e os critérios de construção dos dois painéis amostrais, a estimação da volatilidade, a especificação do VAR e da GFEVD, o procedimento dinâmico via TVP-VAR, a regressão diádica e os procedimentos de visualização de redes. O Capítulo 4 apresenta e discute os resultados, incluindo as considerações finais do trabalho.

2 Revisão Bibliográfica

A noção de risco sistêmico na literatura econômica remonta a trabalhos clássicos que destacam a fragilidade inerente das instituições financeiras. O modelo de corridas bancárias de Diamond e Dybvig (1983) estabelece que bancos são estruturalmente vulneráveis a choques de confiança, nos quais a retirada simultânea de depósitos pode levar ao colapso de instituições solventes. Essa fragilidade não é somente individual, mas de natureza sistêmica, na medida em que a falência de uma instituição pode desencadear efeitos de contágio sobre o restante do sistema financeiro, configurando o caráter sistêmico do risco bancário. A instabilidade pode emergir de forma endógena relacionada à estrutura do próprio sistema, trabalhos subsequentes como o de Allen e Gale (1998) reforçam essa perspectiva. Embora esses modelos estabeleçam os fundamentos da fragilidade financeira, ainda apresentam limitações por operarem sob hipóteses simplificadoras, nas quais a heterogeneidade entre agentes e a complexidade das interações financeiras são limitadas. Como resultado, esses modelos oferecem pouca orientação sobre como a arquitetura das conexões financeiras influencia a propagação de choques em sistemas contemporâneos.

A crise financeira global de 2008 representa um ponto de inflexão na pesquisa sobre risco sistêmico em instituições financeiras. A importância da arquitetura de rede já havia sido demonstrada em Allen e Gale (2000) de modo que as estruturas incompletas de reivindicações interbancárias se mostram mais propensas a episódios de contágio do que estruturas completas. Contudo, foi somente após o colapso de instituições de importância sistêmica que a fragilidade do sistema financeiro e a topologia da rede financeira passaram a ocupar posição central no debate acadêmico e regulatório.

Por meio de uma análise bibliométrica extensa, Silva, Kimura e Sobreiro (2017) documentam essa virada: a literatura sobre estabilidade financeira evoluiu para focar na topologia das redes interbancárias, identificando o contágio via interconectividade como a principal fonte de fragilidade sistêmica contemporânea. A interconectividade cria canais para o contágio e amplificação de choques no sistema financeiro, sendo este o ponto principal de Glasserman e Young (2014) que a identificam como um dos principais determinantes de crises financeiras recentes.

A mesma arquitetura de rede que promove resiliência em tempos de normalidade é a que propaga contágio em momentos de estresse severo. Essa natureza dual é formalizada em Acemoglu, Ozdaglar e Tahbaz-Salehi (2015). O regime de propagação depende, portanto, da magnitude do choque inicial. Uma rede altamente conectada atua como um mecanismo de absorção de choques para choques de baixa magnitude, mas se converte em mecanismo de amplificação e propagação sistêmica quando os choques ultrapassam um limiar crítico. Essa dinâmica de limiar é formalizada de maneira mais ampla pela literatura de cascatas em redes financeiras. Os mecanismos pelos quais as perdas se propagam em cascata é mapeado

extensamente em Glasserman e Young (2016), distinguindo canais de contágio diretos e indiretos. A probabilidade e magnitude de uma cascata dependem conjuntamente da topologia de rede e da distribuição de exposições, fortalecendo a percepção de que a mensuração empírica de conectividade é condição necessária para a avaliação do risco sistêmico.

A literatura converge na ideia de que a interconectividade é elemento central para a compreensão do risco sistêmico. Diverge, porém, quanto à sua mensuração empírica, especialmente em contextos nos quais a estrutura da rede não é diretamente observável. Como resultado, grande parte da literatura depende de proxies indiretas que aproximam imperfeitamente a topologia da rede, ou de bases granulares de acesso restrito mantidas por reguladores, o que compromete a comparabilidade dos resultados e restringe análises empíricas em escala ampla e frequência elevada.

O problema da mensuração indireta encontra uma solução metodológica no *spillover index*, proposto por Diebold e Yilmaz (2009) a partir de dados de mercado de acesso público. A metodologia utiliza um modelo de vetores autorregressivos (VAR) e a decomposição da variância dos erros de previsão para gerar um índice agregado de conectividade, mensurando a interdependência entre ativos ou mercados financeiros. Em outras palavras, o índice quantifica a parcela da variância de uma variável atribuível a choques nas demais, em contraposição à parcela atribuível à própria. Por meio da representação $MA(\infty)$ do VAR e da decomposição de Cholesky, os autores decompõem a variância do erro de previsão em parcelas de variância própria (*own variance shares*), decorrentes de choques na própria variável, e parcelas de variância cruzada (*cross variance shares*). O *spillover index* é construído pela soma das contribuições de choques originados em i sobre o erro de previsão de j (para todo $i \neq j$), normalizada pela variância total do sistema.

Entretanto, o *spillover index* original apresentava duas limitações principais sendo a sensibilidade à ordem das variáveis na decomposição de variância e a dificuldade em identificar a origem e o destino dos choques. Para superar esses desafios, uma refinação da metodologia foi apresentada em Diebold e Yilmaz (2012) ao adotar a Decomposição Generalizada da Variância dos Erros de Previsão (GFEVD), proposta originalmente por Koop, Pesaran e Potter (1996) e Pesaran e Shin (1998). Ao adotar a GFEVD, os autores eliminaram o problema inerente à ordenação das variáveis, característica da decomposição de Cholesky, possibilitando uma identificação invariante da topologia de transmissão de risco. O refinamento metodológico permitiu, ainda, a introdução do conceito de *net spillover*, definido como a diferença entre a contribuição que uma variável transmite ao sistema e aquela que dela recebe, classificando cada variável como transmissora ou receptora líquida de volatilidade. O balanço histórico de Diebold e Yilmaz (2023) consolida o modelo de conectividade dinâmica como a base para a análise macroprudencial, demonstrando que os *spillovers* de mercado refletem fielmente a topologia de transmissão do risco sistêmico.

A matriz de conectividade resultante da GFEVD admite, ainda, uma leitura sob a ótica da teoria das redes como a matriz de adjacência de uma rede complexa, intuição formalizada

em Diebold e Yilmaz (2014). Diferentemente da maior parte da literatura aplicada de redes financeiras, que analisa apenas a existência de conexões entre instituições, a estrutura derivada da GFEVD configura um grafo direcionado e ponderado. A natureza direcionada da rede captura a dinâmica de assimetria do risco financeiro, dado que a contribuição de i para a variância de j não coincide, em geral, com a contribuição inversa.

Dessa estrutura, Diebold e Yilmaz (2014) derivam métricas de conectividade com correspondência direta nas medidas fundamentais da teoria de grafos. O conceito de *from-degree*, que mede a conectividade total recebida pelo nó (equivalente ao *in-degree* em teoria dos grafos), funciona como indicador de vulnerabilidade da variável a choques transmitidos pelos demais elementos do sistema. Em contrapartida, o *to-degree*, equivalente ao *out-degree*, mede a conectividade transmitida pelo nó aos demais e identifica os elementos com maior potencial de propagação sistêmica. O índice agregado de conectividade do sistema, por sua vez, sintetiza a densidade da interdependência da rede, sendo equivalente conceitualmente ao grau médio normalizado de um grafo ponderado.

A abordagem de janelas móveis (*rolling-window*), embora permita capturar a evolução temporal da conectividade, impõe uma limitação relevante em que os parâmetros do modelo são recalculados em janelas fixas e discretas, o que pode obscurecer transições graduais na estrutura da rede. A alternativa é estimar os parâmetros de forma contínua, sem a definição de uma janela fixa. É o que fazem Antonakakis, Chatziantoniou e Gabauer (2020) e Chatziantoniou e Gabauer (2021) ao propor a estimação do índice de conectividade via modelos de parâmetros variantes no tempo (*Time-Varying Parameter VAR* - TVP-VAR). Essa extensão metodológica preserva a interpretabilidade do *framework* de Diebold-Yilmaz, ao mesmo tempo em que oferece uma representação mais contínua e sensível da dinâmica de transmissão de risco, tornando-se especialmente adequada para a análise de sistemas financeiros sujeitos a choques abruptos e regimes variantes. A escolha entre *rolling-window* e TVP-VAR envolve um *trade-off* entre simplicidade interpretativa e suavidade na captura de transições de regime. A abordagem de janelas móveis, embora consiga atenuar efeitos de memória longa característicos de séries de volatilidade financeira não é suficiente para identificar episódios de elevação da conectividade associados já que data defasadamente os movimentos de acordo com o tamanho especificado da janela. Por esse motivo, o TVP-VAR é adotado como especificação principal neste trabalho, com a janela móvel mantida apenas como comparação com a convenção da literatura de referência.

A representação espectral da decomposição da variância permite também analisar os spillovers no domínio da frequência. O risco sistêmico tem dinâmicas distintas. A conectividade gerada em altas frequências reflete o processamento rápido de informações no curto prazo em momentos de calma, enquanto a conectividade gerada em baixas frequências sinaliza choques persistentes e mudanças estruturais nas expectativas dos agentes, sendo esse o ponto central de Baruník e Křehlík (2018). O modelo exige um horizonte de aproximação e uma extensão amostral longos para que o algoritmo de Fourier mapeie as baixas frequências com precisão. Essas escolhas introduzem o risco de sofrer com *overfitting* e problemas de graus de liberdade,

especialmente em janelas amostrais mais curtas.

Também é possível estender a abordagem para o domínio quantílico conforme proposto em Ando, Greenwood-Nimmo e Shin (2022). Os autores demonstraram empiricamente que a transmissão de choques e o risco de contágio são fenômenos de cauda, se apresentam virtualmente ausentes na mediana e se expandem de forma severa em períodos de estresse. Dada a natureza assimétrica e não-linear da conectividade financeira, os modelos baseados na média condicional tendem a subestimar o potencial de contágio sistêmico em momentos de crise. A estimação depende de dados de densidade alta e amostras maiores, o que inviabiliza sua aplicação. A dinâmica temporal de janelas móveis consegue capturar a transição do sistema para a cauda uma vez que a média condicional é dominada por observações extremas em momento de crise, além de ser computacionalmente acessível e estável.

O *spillover index* foi utilizado para analisar a volatilidade dos retornos da rede de instituições financeiras norte-americanas e europeias no período 2004–2014 e caracterizar a dinâmica da conectividade ao longo da crise financeira de 2008 em Diebold e Yilmaz (2016). Os autores argumentam que, no período pós-2008, a transmissão de volatilidade se tornou mais bidirecional, com aumento expressivo da influência das instituições europeias sobre o mercado norte-americano. Além disso, os autores demonstram que, após o colapso do Lehman Brothers, a crise financeira teria adquirido caráter efetivamente global. O estudo evidencia o aprofundamento das conexões entre instituições financeiras em períodos de estresse, corroborando a interpretação de Acemoglu, Ozdaglar e Tahbaz-Salehi (2015) de que a interconectividade que estabiliza em normalidade amplifica choques sob estresse severo.

Para os mercados das Américas Diebold e Yilmaz (2011) analisam empiricamente os *spillovers* de volatilidade entre cinco mercados de ações: EUA, México, Chile, Argentina e Brasil. Os autores identificam que, embora as economias centrais dominem a transmissão em momentos de estresse agudo, as economias latino-americanas exibem fluxos de transmissão regional não desprezíveis. Para o Brasil, especificamente, os resultados indicam que o país não opera como receptor passivo de volatilidade, mas atua como *hub* regional de propagação de volatilidade, refletindo sua centralidade econômica na América Latina. Esse achado motiva investigações mais aprofundadas sobre como a posição do Brasil na rede de *spillovers* se comporta em períodos posteriores, marcados por choques idiossincráticos domésticos.

O risco soberano oferece outro campo de aplicação do *framework* de Diebold-Yilmaz, mensurando os *spillovers* de volatilidade de *credit default swaps* (CDS) entre economias emergentes e avançadas, foco central em Bostanci e Yilmaz (2020). O estudo evidencia que a rede de *spillovers* é altamente integrada e que os mercados emergentes (incluindo o Brasil) assumiram um papel central como transmissores líquidos de volatilidade financeira no período pós-crise. A unidade de análise, porém, é o risco soberano agregado. O CDS reflete o risco de crédito do país como um todo e não a estrutura de transmissão entre instituições individualmente. Permanece em aberto se essa centralidade do Brasil como transmissor líquido se reproduz ou se inverte quando a rede é decomposta nas instituições que a compõem. O país pode ser transmissor líquido

agregado enquanto, internamente, alguns bancos atuam como receptores.

O mercado brasileiro enfrentou, no entanto, ao longo de 2019-2025, uma combinação de choques de natureza distinta daquela observada nos sistemas avançados analisados em Diebold e Yilmaz (2016). Uma pandemia global, um ciclo abrupto de aperto monetário e episódios de instabilidade como a fraude contábil da Americanas sugerindo que a estrutura de rede de *spillovers* brasileira possui determinantes distintos daqueles observados nas economias avançadas. O mercado interbancário brasileiro apresenta estrutura concentrada. As primeiras evidências empíricas em Cajueiro e Tabak (2008) de topologia do mercado interbancário brasileiro sob a ótica das redes complexas demonstram que o sistema exhibe elevada heterogeneidade estruturada em torno de *money centers*, em que o porte e o tipo de controle do capital determinam a centralidade da instituição na rede.

Evidências para o caso brasileiro também sugerem que a estrutura do sistema interbancário brasileiro apresenta uma elevada concentração de conectividade em um número reduzido de instituições de importância sistêmica. Em Silva, De Souza e Tabak (2016), os autores caracterizam a rede interbancária brasileira por meio de medidas de teoria de redes. O artigo documenta que o mercado interbancário brasileiro possui uma estrutura de *core-periphery*, em que o núcleo é composto por um pequeno grupo de bancos grandes e altamente conectados, e a periferia, por um grande número de bancos menores que se conectam ao núcleo, mas raramente entre si próprios. O estudo, contudo, depende de dados granulares e sigilosos mantidos pelo Banco Central do Brasil, inacessíveis ao público e à comunidade científica.

O mesmo problema de dependência de dados sigilosos aparece em Cont, Moussa e Santos (2013), que propõem o *Contagion Index*, a perda esperada do sistema condicional à inadimplência de uma instituição em um período de estresse macroeconômico a partir de uma base de exposições cedidas pelo Banco Central do Brasil. Os achados dialogam com Silva, De Souza e Tabak (2016) já que o sistema exhibe topologia *scale-free*, em que a maioria dos nós possui poucas conexões, enquanto alguns nós, conhecidos como *hubs*, concentram um grande número de conexões. Sob essa topologia, a concentração da exposição e do risco sistêmico em poucos nós centrais favorece a propagação de perdas em cascata, com choques macroeconômicos atuando como mecanismo central de amplificação. A pesquisa, no entanto, tem seu mecanismo de transmissão modelado exclusivamente pelo balanço, ignorando o canal dos preços de mercado pelo qual a incerteza sobre uma instituição se transmite às demais antes que qualquer exposição materialize a perda.

O ΔCoVaR aplicado ao caso brasileiro por Moura, Ferreira e Corrêa (2024), com dados de mercado, demonstra que a contribuição marginal para o risco sistêmico no Brasil está ligada ao perfil de tomada de risco das instituições. Ainda que o estudo evidencie empiricamente que a vulnerabilidade de balanços é relevante para o risco sistêmico, o método não captura a direcionalidade e a topologia da rede em tempo real. Embora o ΔCoVaR identifique a magnitude do impacto potencial de uma instituição sobre o sistema, ele falha em mapear os canais de transmissão e o efeito cascata das interações, tornando necessária uma abordagem complementar

baseada em *spillovers* que desenhe a arquitetura das interações.

Em síntese, as evidências disponíveis para o caso brasileiro partem, predominantemente, de dados sigilosos do Banco Central do Brasil. Essa dependência cria uma lacuna metodológica que exige abordagens complementares fundamentadas em dados públicos de mercado, como os *spillovers* de volatilidade capturados pela metodologia de Diebold-Yilmaz, que permitam uma análise dinâmica, transparente e em alta frequência da conectividade sistêmica, dispensando o acesso a bases sigilosas.

A lacuna de dados públicos encontra resposta parcial em Silva, Passos *et al.* (2025), que visa resolver investigando a conectividade através de dados de ações bancárias listadas no Ibovespa. Utilizando um modelo TVP-VAR e complementando o estudo com métricas de redes complexas, os autores buscam entender como o contágio financeiro se propaga através da rede brasileira. O estudo demonstra que a estrutura de transmissão de volatilidade entre bancos brasileiros é instável e sensível a choques macroeconômicos e políticos, atingindo picos superiores a 50% em períodos de instabilidade política e econômica com Bradesco, Banco do Brasil e Itaú operando como os nós centrais na transmissão de choques. Contudo, o estudo define seu universo amostral por critério de liquidez, sem estratificar as instituições, o que limita a capacidade de caracterizar como a heterogeneidade institucional do sistema bancário influencia a estrutura de transmissão de risco.

O presente trabalho propõe-se a preencher essas lacunas em três frentes. Primeiro, estratifica a amostra por tipo de controle (público, privado nacional e estrangeiro), modelo de negócio (varejo, investimento, atacado e consumo) e porte, tornando a heterogeneidade institucional do sistema bancário brasileiro explícita na análise de *spillovers*. Segundo, vai além das métricas reportadas por Silva, Passos *et al.* (2025) ao comparar explicitamente o ranking de importância sistêmica derivado dos *spillovers* com a segmentação prudencial de D-SIBs publicada pelo Banco Central do Brasil, testando se uma metodologia baseada em dados públicos de mercado é capaz de aproximar a classificação regulatória. Terceiro, incorpora métricas de redes ampliadas, *eigenvector centrality*, PageRank e regressão diádica, sendo esta última raramente reportada em estudos de *spillovers* brasileiros e particularmente adequada para testar se há *clustering* na rede de transmissão de risco.

3 Metodologia

Esta seção apresenta as escolhas metodológicas do trabalho em três subseções. A Subseção 3.1 descreve a base de dados, os critérios de seleção da amostra, a construção das séries de volatilidade e os procedimentos de tratamento dos dados. A Subseção 3.2 apresenta a topologia de redes via Diebold-Yilmaz, incluindo a especificação do VAR, a identificação por decomposição generalizada da variância e os índices de spillover. A Subseção 3.3 detalha a visualização de redes e a interpretação econômica das métricas de centralidade. A notação é declarada na Subseção 3.1 e mantida ao longo de toda a seção.

3.1 Base de Dados

Seleção da amostra

A amostra é composta por oito instituições bancárias com ações negociadas na B3 entre fevereiro de 2019 e dezembro de 2025. A composição foi definida de modo a maximizar três dimensões de heterogeneidade relevantes para o estudo de risco sistêmico: (i) *tipo de controle*, abrangendo bancos privados nacionais, público federal, público estadual e privados estrangeiros; (ii) *perfil de negócio*, cobrindo varejo massificado, banco de investimento, atacado corporativo e crédito ao consumo; e (iii) *porte*, incluindo tanto *large caps* quanto *mid caps*.

A amostra contempla as oito instituições bancárias com ações listadas na B3 que reúnem, em conjunto, representatividade sistêmica e diversidade de perfis de controle e modelo de negócio. Itaú Unibanco (ITUB4) e Bradesco (BBDC4) figuram como os dois maiores bancos privados nacionais, funcionando como *hubs* centrais da rede de conectividade. O Banco do Brasil (BBAS3), como maior instituição pública federal, captura a exposição do sistema a políticas governamentais. O Santander (SANB11) representa o principal canal de transmissão de choques internacionais, na condição de maior banco estrangeiro do país. O BTG Pactual (BPAC11), maior banco de investimento independente da América Latina, contribui com um perfil de *wholesale* distinto dos bancos de varejo tradicionais. O Banrisul (BRSR6), único banco público estadual com liquidez suficiente para o estudo, introduz uma dimensão regional (Rio Grande do Sul) à amostra. O ABC Brasil (ABCB4), por sua vez, diversifica tanto o tipo de controle (privado estrangeiro) quanto o modelo de negócio (*wholesale* puro). Por fim, o Banco Pan (BPAN4) representa o segmento de bancos médios de varejo, com a particularidade de manter relação societária com o BTG Pactual, o que pode gerar *spillovers* par-a-par relevantes entre as duas instituições.

Três instituições com presença relevante no mercado de capitais foram deliberadamente excluídas. O Banco BMG (BMGB4) apresenta perfil de negócio redundante com o Banco Pan, ambos concentrados em crédito consignado e varejo, além de liquidez em bolsa materialmente

inferior. A B3 S.A. (B3SA3) não é uma instituição bancária, mas uma infraestrutura de mercado; sua inclusão alteraria a natureza do estudo. BB Seguridade (BBSE3) e Porto Seguro (PSSA3) são seguradoras e, portanto, sua inclusão deslocaria o foco do sistema bancário para uma rede financeira mais ampla, comprometendo a comparabilidade com as Instituições Financeiras Sistemicamente Importantes Domésticas (D-SIBs) designadas pelo Banco Central do Brasil (BCB).

O recorte temporal de cada instituição não é uma escolha discricionária, mas decorre diretamente do critério de liquidez de um volume financeiro diário inferior a R\$ 100 mil. Seis das oito instituições - ITUB4, BBDC4, BBAS3, SANB11, BRSR6 e ABCB4 - nunca ficam abaixo desse piso ao longo de toda a base disponível, desde 2014. As duas exceções definem as fronteiras efetivas da amostra. O BPAC11 só passa a negociar de forma continuamente líquida a partir de 18/08/2017 - antes disso, a ação, listada em fevereiro de 2017, ainda está em fase de formação de *book*. O BPAN4, por sua vez, só se torna continuamente líquido a partir de 16/01/2019: no terceiro trimestre de 2018, por exemplo, o papel permanece abaixo do piso de liquidez em 44 dos 63 pregões do período, com média de apenas 48 negócios diários.

Essas duas fronteiras, determinadas pelos dados, geram naturalmente dois painéis aninhados, apresentados na Tabela 1. O painel principal (N = 7) exclui o Banco Pan e cobre o período de outubro de 2017 a maio de 2026, o maior alcance temporal possível dado o critério de liquidez das sete instituições restantes. O painel de extensão (N = 8) inclui o Banco Pan e cobre janeiro de 2019 a outubro de 2025.

Tabela 1 – Painéis amostrais com fronteiras determinadas pelos dados

Painel	Janela	Observações	Papel
N = 7 (sem Banco Pan)	10/2017 a 05/2026	2.148	Principal
N = 8 (com Banco Pan)	01/2019 a 10/2025	1.690	Extensão

O vínculo societário BTG-Pan

A hipótese de que o vínculo societário produz co-movimento de volatilidade não pode ser testada no painel principal, pela razão evidente de que nele não há nenhum par de instituições ligadas por controle. Recorre-se, por isso, ao painel de oito instituições, único em que o par BTG e Banco Pan está presente. A restrição não decorre de escolha metodológica, e sim do fato de que, no sistema bancário brasileiro listado, esse é o único vínculo dessa natureza disponível no período.

A Tabela 2 apresenta os coeficientes da regressão diádica com indicadoras por par específico (Equação 3.19), estimada em corte único sobre o painel de extensão. Dois resultados se destacam. O par que compartilha vínculo de controle efetivo, BTG e Pan, apresenta o segundo maior coeficiente da tabela (+5,94 pontos percentuais, $p < 0,0001$), e o par classificado apenas sob a etiqueta nominal de "privado estrangeiro" (ABC Brasil e Santander), duas instituições sem

qualquer proximidade de porte ou modelo de negócio apresenta o único coeficiente negativo ($-2,29$ pontos percentuais, $p = 0,011$). Esse padrão contraria a hipótese puramente categórica de que compartilhar um rotulo de classificação produz, por si só, conectividade adicional, e pode até estar associado a menos.

A leitura não se resume, porém, a ideia de que vínculo societário organiza a rede, categoria nominal não. O par Itaú e Bradesco, os dois maiores bancos privados nacionais da amostra e sem qualquer vínculo de controle entre si, também apresenta coeficiente elevado ($+6,24$ pontos percentuais, $p < 0,0001$). Como a regressão já controla separadamente pelo efeito de ambos serem instituições de grande porte ($+4,10$ pontos percentuais, $p < 0,0001$), o coeficiente de Itaú–Bradesco representa um comovimento adicional, específico do par, que não é explicado nem pela propensão geral de cada banco a transmitir e receber risco, nem pelo porte. Duas explicações são compatíveis com os dados sendo a primeira em relação ao vínculo de controle societário testado nesta subseção e a segunda sobre a proximidade de modelo de negócio e de exposição a choques regulatórios e macroeconômicos comuns aos dois maiores bancos de varejo do país, mecanismo distinto mas igualmente capaz de gerar comovimento além do que porte e propensão geral já explicam. Os dados aqui disponíveis não permitem distinguir entre as duas hipóteses para o par Itaú–Bradesco, na ausência de um vínculo de controle a testar. O achado central da subseção permanece. O mecanismo de controle societário é suficiente para gerar comovimento da mesma magnitude que a maior proximidade de porte e modelo de negócio da amostra, mas não é o único mecanismo capaz de fazê-lo.

Tabela 2 – Regressão diádica com indicadoras por par específico (painel de extensão, corte único)

Indicadora	Coeficiente (p.p.)	<i>t</i>	<i>p</i>
Bradesco e Itaú (privados nacionais)	6,24	8,44	$< 0,0001$
BTG e Pan (vínculo societário)	5,94	7,24	$< 0,0001$
Banco do Brasil e Banrisul (estatais)	0,47	0,93	0,361
ABC Brasil e Santander ("estrangeiros")	$-2,29$	$-2,67$	0,011
Ambos de grande porte	4,10	5,34	$< 0,0001$

Fonte: elaboração própria.

A robustez desse resultado não depende de um único corte amostral. A Tabela 3 reestima a mesma regressão a cada mês, totalizando 82 cortes ao longo do painel de extensão, e resume a série de coeficientes resultante pela média, pela proporção de meses com sinal positivo e por um teste *t* da média contra zero. O par BTG–Pan mantém sinal positivo em 74 dos 82 cortes (90%), com média de 5,26 pontos percentuais ($t = 12,8$); o par Itaú–Bradesco e a indicadora de porte mantêm sinal positivo em todos os 82 cortes; o par ABC Brasil–Santander mantém sinal negativo na grande maioria deles (apenas 17 de 82 positivos). A evidência não repousa, portanto, sobre o resultado pontual de uma única estimação, mas sobre a repetição do padrão de sinal ao longo de quase sete anos de dados mensais.


Tabela 3 – Regressão diádica por par específico — extensão temporal (84 cortes mensais)

Indicadora	Média (p.p.)	Sinal positivo	<i>t</i>	<i>p</i>
Bradesco e Itaú (privados nacionais)	6,44	82/82	19,66	< 0,0001
BTG e Pan (vínculo societário)	5,26	74/82	12,8	< 0,0001
Banco do Brasil e Banrisul (estatais)	0,68	49/82	3,29	0,0015
ABC Brasil e Santander ("estrangeiros")	-1,21	17/82	-5,98	< 0,0001
Ambos de grande porte	3,51	82/82	22,95	< 0,0001

Fonte: elaboração própria.

A Figura 1 mostra a evolução do coeficiente do par BTG–Pan ao longo do tempo, e não apenas sua média. A série atinge seu valor máximo em 2022 (9,52 pontos percentuais em média anual), um ano após o BTG Pactual assumir o controle pleno do Banco Pan, em maio de 2021, ao adquirir a totalidade da participação até então detida pela Caixa Econômica Federal e encerrar o controle compartilhado que mantinha desde 2011 (**btgpactual2021**)¹. O intervalo de um ano entre a consolidação do controle e o pico do coeficiente é compatível com uma reprecificação gradual do vínculo entre as duas instituições pelo mercado, e não com um efeito instantâneo. Após o pico, o coeficiente cai de forma contínua até 2024 (1,19 ponto percentual, o mínimo da série), voltando a subir em 2025 (1,77 pontos percentuais) em um movimento que coincide com o anúncio de incorporação total do Pan pelo BTG, em outubro de 2025.

Figura 1 – Coeficiente da regressão diádica: BTG-Pan



Fonte: elaboração própria.

A conclusão da subseção decorre desse mesmo anúncio. Até 13/10/2025, os retornos diários do Pan e do BTG apresentam correlação moderada, em torno de 0,39 a 0,43 em janelas

¹Fonte a confirmar/ajustar conforme a norma de citação adotada.

comparáveis antes e depois do anúncio. Essa correlação do período pós-anúncio tomado como um todo, contudo, mistura duas fases distintas do processo: as semanas iniciais, em que a conclusão do negócio ainda dependia de aprovações societárias e regulatórias, e as semanas finais, em que a relação de troca fixa entre os papéis (0,2128 *unit* do BTG por ação do Pan) já era essencialmente certa. A correlação móvel de curto prazo revela essa transição: nos últimos 10, 30 e 60 pregões de negociação do Pan antes da deslistagem, a correlação converge para 0,96, 0,97 e 0,97, respectivamente. Esse movimento é consistente com o mecanismo de arbitragem esperado quando a conclusão da fusão se torna praticamente certa. Não foi possível identificar, entre os comunicados ao mercado disponíveis, um fato relevante específico na data exata em que essa convergência se inicia (28/10/2025, identificada por correlação móvel de curta janela), que antecede em cerca de seis semanas a aprovação em assembleia geral (09/12/2025), os marcos formais do processo documentados publicamente ocorrem majoritariamente depois dessa data.

Esse fato cumpre dois papéis na subseção. Primeiro, explica por que o painel de extensão se encerra em 13/10/2025: com a correlação entre os dois papéis convergindo para próximo de 1 ao final do processo, as duas séries deixam de ser distinguíveis para fins de decomposição de variância, e a estimação do VAR se tornaria numericamente degenerada se estendida além desse ponto. Segundo, e mais importante, confirma que se o vínculo de controle societário aproxima o comportamento de duas ações, a fusão completa deveria aproximá-las ao limite já que é o vínculo societário mais forte possível. Foi exatamente o que se observou. O resultado que a subseção buscou estabelecer com efeitos fixos e dados mensais ao longo de sete anos é confirmado através desse fato.

O resultado desta subseção não é levado ao painel principal de sete instituições porque o vínculo societário se encerrou no mundo real com a incorporação. Em contrapartida, é o painel principal que permite alcançar o regime de conectividade elevada de 2026, fora do alcance do painel de extensão.

Construção das séries de volatilidade

Justificativa da variável-alvo

A variável-alvo deste estudo é a volatilidade das ações dos bancos selecionados, e não os retornos. Essa escolha é motivada pelo próprio objeto de análise: importância sistêmica, no sentido adotado pelo BCB para a designação de D-SIBs, é um conceito de segundo momento e refere-se à capacidade de uma instituição propagar *estresse* pelo sistema financeiro, não apenas retornos. Spillovers de volatilidade capturam precisamente essa dimensão e são tipicamente maiores, mais informativos e mais robustos a mudanças de regime do que spillovers de retornos (Diebold; Yilmaz, 2009). Ademais, a janela amostral escolhida (2019–2025) concentra episódios cujos efeitos se manifestaram primordialmente na volatilidade como COVID-19, ciclo de aperto da Selic em 2022 e fraude contábil da Americanas em 2023. Por fim, a presença de *mid caps* na amostra, cujo volume de negociação é irregular, recomenda o uso de medidas *range-based*, mais

robustas ao ruído de microestrutura do que retornos diários *close-to-close*.

Estimador Rogers-Satchell

A volatilidade é mensurada por um estimador *range-based* de um único dia, sem sobreposição entre observações consecutivas, que combina o componente de Rogers e Satchell (1991), independente de drift intradiário, com um termo de retorno *overnight*:

$$\hat{\sigma}_t^2 = \hat{\sigma}_t^2 + \widehat{RS}_t, \quad (3.1)$$

onde

$$\hat{\sigma}_t^2 = \left[\log\left(\frac{O_t}{C_{t-1}}\right) \right]^2, \quad (3.2)$$

$$\widehat{RS}_t = \log\left(\frac{H_t}{C_t}\right) \log\left(\frac{H_t}{O_t}\right) + \log\left(\frac{L_t}{C_t}\right) \log\left(\frac{L_t}{O_t}\right). \quad (3.3)$$

Aqui H_t , L_t , O_t e C_t denotam os preços máximo, mínimo, de abertura e de fechamento no dia t , respectivamente, e C_{t-1} o preço de fechamento do pregão anterior. Diferentemente de estimadores de amplitude baseados em janela móvel de n dias, as Equações 3.1–3.3 produzem uma estimativa de variância por pregão, sem exigir médias amostrais calculadas sobre uma janela: cada observação é independente das demais, eliminando por construção qualquer sobreposição de dados entre estimativas consecutivas. A variável efetivamente utilizada nas estimações é $y_t = \log(\max(\hat{\sigma}_t \sqrt{252}, 10^{-8}))$, onde $\hat{\sigma}_t = \sqrt{\hat{\sigma}_t^2}$ é anualizado pela convenção de 252 pregões por ano, seguindo a mesma prática de anualização adotada por Diebold e Yilmaz (2012) e Diebold e Yilmaz (2014), e o piso numérico evita indeterminação logarítmica nos raros pregões de variância estimada nula. A transformação logarítmica aproxima a distribuição dos choques de um padrão gaussiano, facilitando a inferência no VAR.

Por que Rogers-Satchell e não estimadores alternativos?

O estimador de Garman-Klass ignora a variação *overnight* (C_{t-1} a O_t), tratando o ativo como se nada ocorresse fora do pregão. Para o sistema bancário brasileiro no período 2019–2025, isso é particularmente problemático já que decisões do Comitê de Política Monetária (Copom) são divulgadas após o fechamento do mercado, resultados trimestrais são publicados *after-market* e dados macroeconômicos norte-americanos chegam durante a tarde-noite no horário de Brasília. A literatura empírica em ações brasileiras estima que entre 40% e 50% da variância total ocorre *overnight*, de modo que descartar essa componente subestima sistematicamente a volatilidade efetiva. Adicionalmente, Garman-Klass assume *drift* intradiário nulo, o que o torna positivamente viesado em janelas com tendência marcada como em março de 2020 (COVID-19) e janeiro de 2023 (Americanas). O estimador de Parkinson utiliza apenas os extremos (H_t e L_t), sendo estritamente menos eficiente do que Garman-Klass, que incorpora O_t e C_t .

A volatilidade realizada (RV) intradiária exigiria dados de *tick*, indisponíveis abertamente para o período amostral completo. Mesmo com acesso a dados de alta frequência, medições

a 5 minutos produzem viés por *bid-ask bounce*, e as correções técnicas associadas fogem do escopo deste trabalho. A presença de *mid caps* na amostra agrava o problema de modo que dias sem negociação contínua geram zeros artificiais que inflam RV . A abordagem GARCH(1,1) introduziria uma camada paramétrica adicional antes do VAR, gerando duas etapas de modelagem encadeadas que complicam a interpretação e a robustez, além de operar apenas com retornos *close-to-close*, descartando a informação intradiária que torna os estimadores *range-based* mais eficientes.

A escolha inicial desse trabalho recaiu sobre o estimador de Yang e Zhang (Yang; Zhang, 2000), que combina os mesmos componentes de *drift* independente e retorno *overnight* em uma janela móvel de n dias. Essa escolha, no entanto, não resiste ao diagnóstico dos resíduos. A janela de $n = 21$ dias, recalculada a cada pregão, faz com que observações consecutivas compartilhem $n - 1$ dos n dias da janela, essa estrutura induz autocorrelação na série de log-volatilidade e não reflete a dinâmica econômica real, a diferença passa a ser o dia que entra e o dia que sai da janela a cada atualização. Essa autocorrelação se propaga diretamente para os resíduos do VAR estimado sobre a série, violando a hipótese de ruído branco que sustenta a validade da decomposição de variância subsequente, os critérios de seleção de defasagem chegam a cair de forma descontínua no número de defasagens correspondente ao tamanho da janela, sinal de que o modelo está simplesmente reconhecendo a memória embutida no estimador e não capturando dinâmica genuína dos dados.

A sobreposição, contudo, é autoinflingida pela escolha de uma janela de múltiplos dias. Para Diebold e Yilmaz (2012), Diebold e Yilmaz (2014) e Demirer *et al.* (2018), os autores empregam estimadores de amplitude de um único dia e a janela não é utilizada em suas aplicações de referência do *framework* de conectividade. A substituição por Rogers-Satchell com termo *overnight* preserva os dois pilares da escolha original, a cobertura do risco *overnight* e a independência em relação ao *drift*, sem herdar a estrutura de médias móveis induzida pela janela e sem exigir os primeiros $n - 1$ pregões de cada série como aquecimento. Os testes de estacionariedade são conduzidos sobre a série resultante dessa substituição.

Período amostral

O período amostral abrange de fevereiro de 2019 a dezembro de 2025. Esse recorte garante que todas as oito instituições já tenham concluído seus IPOs e apresentem histórico suficiente de negociação. Adicionalmente, o período concentra os principais episódios de estresse do sistema financeiro brasileiro recente, cujos efeitos sobre a volatilidade bancária são centrais para a análise dinâmica: a crise da COVID-19 e os *circuit breakers* de março de 2020, o ciclo de aperto monetário da Selic entre 2022 e 2023, a fraude contábil da Americanas (janeiro de 2023) e o estresse fiscal do segundo semestre de 2024. A Tabela 4 apresenta os principais eventos de *drift* identificados na janela amostral.

Tabela 4 – Principais eventos de *drift* no período amostral (2019-2025)

Período	Direção	Causa
Mar./2020	Negativo extremo	<i>Crash</i> COVID-19
Abr.–dez./2020	Positivo persistente	Recuperação pós- <i>crash</i>
Jan.–set./2022	Negativo persistente	Aperto da Selic
Jan.–mar./2023	Negativo (ITUB4, BBDC4)	Fraude Americanas
Ago.–dez./2023	Positivo (<i>large caps</i>)	Início do ciclo de corte da Selic
Mai./2024 (BRSR6)	Negativo idiossincrático	Enchentes no Rio Grande do Sul
Out.–dez./2024	Negativo persistente	Crise fiscal pós-pacote governamental
Jan.–abr./2025	Negativo (sistema)	Tarifas Trump pós-posse
Mai.–dez./2025	Positivo (<i>large caps</i>)	Expansão de <i>spread</i> bancário

Tratamento dos dados

Os procedimentos de tratamento são aplicados na seguinte ordem.

1. Extração dos dados

Os dados OHLC de todas as oito instituições foram obtidos da base ComDinheiro. Os preços são fornecidos já ajustados retroativamente por proventos considerando dividendos, juros sobre capital próprio, bonificações, *splits*, *inplits* e cisões (*spin-offs*). A escolha por essa fonte foi motivada por duas limitações identificadas. Primeiro, o Banco Pan (BPAN4) deixou de ser negociado ao final de janeiro de 2026, em decorrência da incorporação ao BTG Pactual, o que tornou o *ticker* indisponível em provedores que não mantêm o histórico de ativos descontinuados. Segundo, o ajuste automático de provedores como o Yahoo Finance corrige dividendos e *splits* mas não cisões. A série de ITUB4, por exemplo, registraria uma queda de aproximadamente $-19,8\%$ decorrente da cisão do braço de operações de cartões do Itaú, em um movimento que não reflete volatilidade de mercado real. Caso não corrigido, a estimação dos *spillovers* seria distorcida nas janelas que cobrem o período.

2. Verificação de consistência

Antes da estimação da volatilidade, os dados OHLC são submetidos a verificações de consistência lógica: $H_t \geq L_t$, $H_t \geq O_t$, $H_t \geq C_t$, $L_t \leq O_t$, $L_t \leq C_t$ e $O_t, C_t > 0$. Violações indicam erros de digitação ou de *parsing* no provedor de dados, que produzem valores NaN na estimação de Yang-Zhang e falham silenciosamente.

3. Filtro de liquidez

Dias com volume financeiro inferior a R\$ 100 mil são marcados como NA. Para as *mid caps* ABCB4, BPAN4 e BRSR6, dias com volume muito reduzido produzem *ranges* ($H_t - L_t$) que

refletem o *bid-ask spread* da microestrutura, e não a volatilidade efetiva do ativo. Observações filtradas são tratadas na etapa de imputação.

4. Tratamento de outliers

Retornos extremos são identificados pelo escore padronizado $z_t = (r_t - \bar{r})/\hat{\sigma}_r$ calculado sobre os retornos *close-to-close*, sendo $|z_t| > 5$ o critério de sinalização. Para cada observação sinalizada, verifica-se: se múltiplas instituições registram retorno extremo na mesma data, o evento é classificado como real e mantido; se apenas uma instituição apresenta retorno extremo sem notícia identificável, a observação é conferida em fonte alternativa. Como referência, 12 e 16 de março de 2020 (*circuit breakers* da COVID-19) e 12 de janeiro de 2023 (Americanas, restrito a ITUB4 e BBDC4) são eventos reais e são preservados na amostra.

5. Estimação da volatilidade

A volatilidade Rogers-Satchell é estimada conforme as equações 3.1–3.3. Aplica-se um piso numérico de 10^{-8} antes da transformação logarítmica: $y_t = \log(\max(\hat{\sigma}_{YZ,t}, 10^{-8}))$.

6. Alinhamento e imputação

As oito séries de log-volatilidade são alinhadas por interseção de datas de pregão, formando um painel $T \times 8$. Dias em que todas as séries apresentam NA (finais de semana, feriados) são excluídos. Observações isoladas com NA decorrentes do filtro de liquidez ou de erros de provedor são imputadas por filtro de Kalman aplicado a um modelo ARIMA selecionado automaticamente². A integridade do painel é verificada ao final pela ausência de qualquer NA residual.

Propriedades estatísticas

A estacionariedade de cada série de log-volatilidade é testada por meio do teste de Dickey-Fuller Aumentado (ADF), o teste KPSS, o teste DF-GLS, o teste de Phillips-Perron e o teste de Zivot-Andrews. Séries de log-volatilidade financeira frequentemente exibem memória longa, de modo que tanto o ADF quanto o KPSS podem rejeitar suas respectivas hipóteses nulas simultaneamente (Andersen; Bollerslev; Diebold; Ebens, 2001; Andersen; Bollerslev; Diebold; Labys, 2003; Diebold; Inoue, 2001). Esse padrão de rejeição simultânea não constitui evidência de raiz unitária. A estimação por janela rolante também constitui uma resposta natural à não-estacionariedade de longo prazo. Ao estimar o VAR sobre janelas de $W = 200$ dias, a dinâmica de memória longa e as quebras de regime da amostra completa são atenuadas e cada

²O filtro de Kalman fornece estimativas ótimas de estados não observados em um modelo de espaço de estados, minimizando o erro quadrático médio da predição. Neste contexto, o modelo ARIMA descreve a dinâmica autorregressiva da série de log-volatilidade e o filtro utiliza toda a informação disponível, observações passadas e futuras (*smoother*) para imputar os valores ausentes. Para detalhes, consultar Moritz e Bartz-Beielstein (2017).

janela se aproxima de um processo estacionário no curto prazo. A presença de autocorrelação serial e heterocedasticidade condicional é verificada pelos testes de Ljung-Box e ARCH-LM, respectivamente.

3.2 Topologia de Redes via Diebold-Yilmaz

Especificação do VAR

Seja $\mathbf{y}_t = (y_{1t}, \dots, y_{Nt})'$ o vetor $N \times 1$ das séries de log-volatilidade, com $N = 8$. O modelo VAR de ordem p é:

$$\mathbf{y}_t = \mathbf{c} + \sum_{i=1}^p \Phi_i \mathbf{y}_{t-i} + \boldsymbol{\varepsilon}_t, \quad \boldsymbol{\varepsilon}_t \sim (\mathbf{0}, \boldsymbol{\Sigma}), \quad (3.4)$$

onde $\mathbf{c}$ é um vetor de constantes, Φ_i são matrizes $N \times N$ de coeficientes autorregressivos e $\boldsymbol{\varepsilon}_t$ é um vetor de inovações com matriz de covariância $\boldsymbol{\Sigma}$. Os parâmetros são estimados por Mínimos Quadrados Ordinários (MQO) equação a equação, estimador implementado pelo pacote `ConnectednessApproach` (Gabauer, 2022).

A especificação principal adota $p = 2$ defasagens. Essa escolha reflete dois critérios. Primeiro, a parcimônia: com janela rolante de $W = 200$ dias úteis, o modelo $\text{VAR}(p)$ com $N = 8$ variáveis possui $N^2p + N = 136$ parâmetros no total. Como a estimação é feita por MQO equação a equação, o parâmetro relevante para a estabilidade numérica não é o total do sistema, mas a razão observações/parâmetros por equação: cada uma das N equações possui $Np + 1 = 17$ regressores, de modo que essa razão é de $T_w/(Np + 1) = 200/17 \approx 11,7$ para $p = 2$. Com $p = 4$, essa razão cai para $200/33 \approx 6,1$, deteriorando a estabilidade numérica da estimação. Segundo, consistência com a literatura: Diebold e Yilmaz (2009) e Diebold e Yilmaz (2012) adotam $p = 2$ como especificação de referência em amostras similares.

A condição de estabilidade do VAR exige que todas as raízes do polinômio característico $\det(\mathbf{I}_N - \Phi_1 z - \dots - \Phi_p z^p) = 0$ encontrem-se fora do círculo unitário no plano complexo, equivalentemente, que os módulos dos autovalores da matriz companheira sejam estritamente menores que um. Essa condição garante que o VAR admita a representação de média móvel de ordem infinita $\mathbf{y}_t = \sum_{h=0}^{\infty} \mathbf{A}_h \boldsymbol{\varepsilon}_{t-h}$, utilizada na decomposição de variância subsequente.

Identificação via GFEVD

A identificação dos spillovers baseia-se na *Generalized Forecast Error Variance Decomposition* (GFEVD) de Pesaran e Shin (1998). Dado o horizonte de previsão τ , a fração da variância do erro de previsão de i atribuída a choques em j é:

$$\theta_{ij}^\tau = \frac{\sigma_{jj}^{-1} \sum_{h=0}^{\tau-1} (\mathbf{e}_i' \mathbf{A}_h \Sigma \mathbf{e}_j)^2}{\sum_{h=0}^{\tau-1} \mathbf{e}_i' \mathbf{A}_h \Sigma \mathbf{A}_h' \mathbf{e}_i}, \quad (3.5)$$

onde σ_{jj} é o j -ésimo elemento diagonal de Σ e $\mathbf{e}_i$ é o i -ésimo vetor canônico. A identificação generalizada de Pesaran e Shin distingue-se da decomposição de Cholesky por não impor ordenação recursiva, eliminando a sensibilidade dos resultados a permutações da ordem do VAR. Como contrapartida, as linhas da matriz $\Theta^\tau = [\theta_{ij}^\tau]$ não somam necessariamente um. Aplica-se normalização linha-a-linha:

$$\tilde{\theta}_{ij}^\tau = \frac{\theta_{ij}^\tau}{\sum_{j=1}^N \theta_{ij}^\tau}, \quad (3.6)$$

de modo que $\sum_{j=1}^N \tilde{\theta}_{ij}^\tau = 1$ e $\sum_{i,j=1}^N \tilde{\theta}_{ij}^\tau = N$ por construção. O horizonte é fixado em $\tau = 10$ dias úteis, seguindo a convenção de Diebold e Yilmaz (2009), Diebold e Yilmaz (2012) e Diebold e Yilmaz (2014).

Índices de *spillover*

A partir da matriz normalizada $\tilde{\Theta}^\tau$, definem-se os índices de conectividade de Diebold e Yilmaz (2012): o índice de conectividade total, os índices direcionais de transmissão e recepção de choques, o índice líquido por instituição e o índice líquido par-a-par.

$$\text{TCI} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^N \tilde{\theta}_{ij}^\tau \times 100, \quad (3.7)$$

$$\text{FROM}_i = \sum_{\substack{j=1 \\ j \neq i}}^N \tilde{\theta}_{ij}^\tau \times 100, \quad (3.8)$$

$$\text{TO}_j = \sum_{\substack{i=1 \\ i \neq j}}^N \tilde{\theta}_{ij}^\tau \times 100, \quad (3.9)$$

$$\text{NET}_i = \text{TO}_i - \text{FROM}_i, \quad (3.10)$$

$$\text{NET}_{ij} = \tilde{\theta}_{ji}^\tau - \tilde{\theta}_{ij}^\tau. \quad (3.11)$$

O *Total Connectedness Index* (TCI) em (3.7) mede a fração média da variância do erro de previsão de cada banco explicada por choques nos demais. FROM_i (3.8) quantifica a

receptividade sistêmica de i ; TO_j (3.9) mede a transmissão sistêmica de j ; NET_i (3.10) classifica as instituições como transmissores líquidos ($NET_i > 0$) ou receptores líquidos ($NET_i < 0$); NET_{ij} (3.11) captura a direção líquida do fluxo de risco entre cada par de instituições.

Para além dos índices direcionais propostos por Diebold e Yilmaz (2012), este trabalho incorpora um conjunto de métricas de teoria de redes, centralidade de intermediação (*betweenness*), centralidade de autovetor, assortatividade e PageRank, calculadas sobre o grafo de conectividade $G = (V, E, W)$ definido na Seção 3.3. Essa incorporação constitui uma contribuição adicional do trabalho. Enquanto a literatura de *spillover* de volatilidade concentra-se nos índices direcionais de primeira ordem (quanto cada instituição transmite e recebe diretamente), as métricas de rede capturam a posição estrutural de cada banco na topologia de contágio, incluindo efeitos indiretos e recursivos. O caso mais ilustrativo é o PageRank, cuja formulação recursiva atribui a i um valor elevado quando i recebe *spillovers* de instituições que, por sua vez, também possuem PageRank elevado. A interpretação econômica é a de contribuição recursiva de risco, de modo que um banco é sistemicamente importante não apenas pela intensidade de seus *spillovers* diretos, mas por estar conectado a outras instituições igualmente centrais, lógica análoga à do *framework* de bancos sistemicamente importantes (D-SIB) adotado pelo Banco Central do Brasil. O contraste central deste trabalho é a confrontação entre o ranking de importância sistêmica gerado por essas métricas de rede e a segmentação oficial de D-SIBs publicada pelo BCB.

Especificação dinâmica: TVP-VAR com fatores de esquecimento

A especificação dinâmica principal deste trabalho estima os coeficientes do VAR e a covariância dos choques como variantes no tempo, em vez de recalculá-los em janelas móveis fixas e discretas. Nessa última abordagem, o índice de conectividade estimado em uma data t reflete uma média retrospectiva sobre os W dias anteriores, de modo que o pico de conectividade de um episódio de crise é datado na borda direita da janela, quando esta está mais preenchida por observações do episódio e não na data em que o episódio de fato ocorre.

Seja $z_t = (y'_{t-1}, \dots, y'_{t-p}, 1)'$ o vetor de regressores no instante t e $Z_t = I_N \otimes z'_t$. O modelo (3.4) é reescrito em forma de espaço de estados, com o vetor de coeficientes β_t (dimensão $N(Np+1)$, correspondente ao empilhamento de $\Phi_1, \dots, \Phi_p, c$ de todas as equações) evoluindo como um passeio aleatório:

$$y_t = Z_t \beta_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \Sigma_t), \quad (3.12)$$

$$\beta_t = \beta_{t-1} + u_t, \quad u_t \sim N(0, Q_t). \quad (3.13)$$

A estimação exata de (3.12)–(3.13) por métodos bayesianos completos, como em **primiceri2005** e no corrigendum de **delnagro2015**, exige amostragem MCMC (algoritmo de Carter-Kohn) recomputada a cada iteração, sendo computacionalmente inviável para um estado de dimensão $N(Np+1)$ superior a cem, como é o caso deste trabalho, e originalmente concebida para sistemas de poucas variáveis. A alternativa adotada, proposta por **koopkorobilis2013** e aplicada ao contexto de conectividade por Antonakakis, Chatziantoniou e Gabauer (2020) e Chatziantoniou

e Gabauer (2021), substitui a covariância de estado Q_t e a covariância dos choques Σ_t por estimativas recursivas governadas por dois fatores de esquecimento, κ_1 e κ_2 , dispensando a amostragem MCMC.

O fator κ_1 governa a velocidade de deriva dos coeficientes. Em vez de estimar Q_t diretamente, impõe-se $Q_t = (\kappa_1^{-1} - 1) P_{t-1|t-1}$, onde $P_{t|t}$ é a covariância do estado no filtro de Kalman. Essa imposição faz a etapa de predição do filtro colapsar em:

$$P_{t|t-1} = P_{t-1|t-1} + Q_t = \frac{1}{\kappa_1} P_{t-1|t-1}. \quad (3.14)$$

Com $\kappa_1 = 1$, tem-se $Q_t = 0$, os coeficientes não se movem e o modelo colapsa no VAR de parâmetros constantes da especificação estática. Com $\kappa_1 < 1$, a covariância do estado é inflada a cada período, abrindo espaço para deriva: uma observação de j períodos atrás entra com peso κ_1^j na estimativa filtrada de β_t , de modo que a amostra efetiva de memória do filtro é da ordem de $(1 - \kappa_1)^{-1}$ observações.

O fator κ_2 governa a velocidade de adaptação da covariância dos choques, atualizada por média móvel exponencial dos resíduos do próprio filtro:

$$\Sigma_t = \kappa_2 \Sigma_{t-1} + (1 - \kappa_2) \hat{e}_t \hat{e}_t', \quad \hat{e}_t = y_t - Z_t \beta_{t|t}. \quad (3.15)$$

Como a conectividade em cada instante t é computada a partir de $\beta_{t|t}$ e Σ_t , é κ_2 que determina a velocidade de reação do índice a um episódio de estresse; κ_1 , por sua vez, diz respeito à estrutura de propagação, não à intensidade dos choques que se propagam.

A seleção de (κ_1, κ_2) é conduzida por verossimilhança preditiva fora da amostra, deixando os próprios dados escolherem o par. O filtro de Kalman produz, a cada instante t e condicional à informação disponível até $t - 1$, a densidade preditiva

$$y_t \mid \mathcal{I}_{t-1} \sim N(Z_t \beta_{t|t-1}, F_t), \quad F_t = Z_t P_{t|t-1} Z_t' + \Sigma_{t-1}, \quad (3.16)$$

avaliada no valor efetivamente observado, cuja log-verossimilhança no instante t é

$$\ell_t(\kappa_1, \kappa_2) = -\frac{1}{2} [N \log(2\pi) + \log |F_t| + e_t' F_t^{-1} e_t], \quad e_t = y_t - Z_t \beta_{t|t-1}. \quad (3.17)$$

Como e_t é construído com $\beta_{t|t-1}$, os coeficientes antes de o filtro observar y_t , a penalização por excesso de flexibilidade é automática e um κ_1 baixo permite que os coeficientes persigam ruído, e coeficientes que perseguem ruído preveem pior um passo à frente, reduzindo ℓ_t .

O procedimento de seleção segue quatro etapas. Primeiro, define-se uma grade $\kappa_1 \in \{0,94; 0,96; 0,98; 0,99; 0,995; 1,00\}$ e $\kappa_2 \in \{0,94; 0,96; 0,99\}$, incluindo valores baixos mesmo sabendo, a priori, que tendem a perder. É a distância entre eles e o vencedor que sustenta a robustez da escolha. Segundo, estima-se um VAR(p) por MQO nas primeiras $t_0 = 200$ observações, usando as estimativas resultantes como β_0 , P_0 (a covariância dos coeficientes) e Σ_0 (a covariância dos resíduos) para inicializar o filtro. Terceiro, o filtro é executado, para cada par da grade, ao longo da amostra completa, acumulando ℓ_t apenas para $t > t_0$ — o que torna

o critério genuinamente fora da amostra, já que o período de inicialização não entra na soma $\mathcal{L}(\kappa_1, \kappa_2) = \sum_{t>t_0} \ell_t(\kappa_1, \kappa_2)$. Quarto, as somas são convertidas em pesos posteriores por

$$w(\kappa) \propto \exp \left\{ \mathcal{L}(\kappa) - \max_{\kappa'} \mathcal{L}(\kappa') \right\}, \quad (3.18)$$

normalizados para somar um, com a subtração do máximo antes da exponenciação evitando estouro numérico. O par vencedor é aquele de maior peso posterior, restrito a $\kappa_1 < 1$: o pacote `ConnectednessApproach` exige esse parâmetro estritamente menor que um, já que $\kappa_1 = 1$ corresponde, por definição, ao caso degenerado de coeficientes constantes. Os resultados completos da grade são reportados no Capítulo 4.

Regressão diádica

A hipótese de que o tipo de controle institucional organiza a topologia da rede (testada, na especificação original deste trabalho, por assortatividade nominal sobre o grafo completo) não se sustenta como formulada. A assortatividade nominal compara a fração de ligações que ocorrem dentro de categorias com a fração esperada sob distribuição aleatória, dadas as marginais. Em um grafo com apenas $N = 8$ nós e categorias de tamanho reduzido, essa fração é mecanicamente pequena mesmo quando a categoria não organiza nada, de modo que a estatística tende a um valor negativo por construção, um viés que a normalização usual da estatística, válida assintoticamente para grafos grandes, não corrige em amostras desse tamanho. Mais relevante ainda é que sem ponderação pelos pesos $\tilde{\theta}_{ij}^\tau$, a estatística conta cada aresta do grafo completo como igual às demais, de modo que seu valor depende apenas dos tamanhos dos grupos de cada categoria, não da intensidade real de *spillover* entre os bancos.

A alternativa adotada é um método de dados diádicos, no espírito de um modelo gravitacional onde a unidade de observação deixa de ser o banco e passa a ser o par ordenado (i, j) , $i \neq j$. A matriz $\tilde{\Theta}^\tau$ tem $N(N - 1)$ elementos fora da diagonal, cada um deles uma observação quanto o banco j explica da variância do erro de previsão do banco i . Estima-se, por Mínimos Quadrados Ordinários,

$$100 \tilde{\theta}_{ij}^\tau = \mu + \alpha_j + \gamma_i + \beta D_{ij}^{\text{ctrl}} + \delta D_{ij}^{\text{porte}} + \varepsilon_{ij}, \quad i \neq j, \quad (3.19)$$

em que α_j é um efeito fixo de emissor, γ_i um efeito fixo de receptor, D_{ij}^{ctrl} vale um quando i e j compartilham o mesmo tipo de controle institucional e D_{ij}^{porte} vale um quando ambos são instituições de grande porte. Os efeitos fixos absorvem toda a propensão geral de cada banco a transmitir (α_j) ou a receber (γ_i) risco de qualquer contraparte; o que resta em $\tilde{\theta}_{ij}^\tau$ depois de descontados esses efeitos é o que aquele par específico tem de particular, já que D_{ij}^{ctrl} e D_{ij}^{porte} são propriedades da combinação (i, j) , não de nenhum dos dois bancos isoladamente, e portanto não são absorvidas pelos efeitos fixos. Os erros-padrão são clusterizados por par não dirigido, já que $\tilde{\theta}_{ij}^\tau$ e $\tilde{\theta}_{ji}^\tau$ nascem da mesma relação bilateral e seus resíduos não são independentes entre si.

A Equação (3.19) é estimada tanto sobre o corte único do full sample estático quanto, para o par de instituições ligadas por controle societário efetivo presente no painel de extensão, sobre

uma sequência de cortes mensais extraídos da própria estimação TVP-VAR, o que permite avaliar se o sinal do efeito se repete ao longo do tempo e não apenas em uma estimativa pontual. Os resultados de ambas as estimações, incluindo a substituição de D_{ij}^{ctrl} por indicadoras específicas para cada par que compartilha categoria, são apresentados no Capítulo 4.

3.3 Visualização de Redes

A matriz normalizada $\tilde{\Theta}^\tau$ define a matriz de adjacência de um grafo dirigido ponderado $G = (V, E, W)$, em que V representa as oito instituições, E o conjunto de arestas de transmissão de variância e W os pesos $\tilde{\theta}_{ij}^\tau$. A convenção de direção é: $\tilde{\theta}_{ij}^\tau$ representa o fluxo de j para i (o choque em j explica parcela da variância do erro de previsão de i). Como o pacote `igraph` interpreta o elemento `mat[i, j]` como aresta saindo de i e chegando em j , a matriz é transposta antes da construção do grafo para preservar a semântica econômica.

Os índices definidos na Subseção 3.2 são mapeados em atributos visuais do grafo: (i) o tamanho do nó é proporcional ao índice TO_i ; (ii) a cor do nó é codificada pelo índice NET_i por meio de uma paleta divergente, distinguindo transmissores líquidos de receptores líquidos; (iii) a espessura de cada aresta é proporcional ao *spillover* par-a-par NET_{ij} ; e (iv) a forma ou contorno do nó codifica o tipo de controle institucional.

A rede DY é quase completa: com $N = 8$, há até 56 arestas dirigidas. Para fins de visualização exclusivamente, aplica-se um *threshold* de 5% sobre os pesos $\tilde{\theta}_{ij}^\tau$, retraindo apenas as conexões mais intensas. Esse filtro não afeta a inferência conduzida a partir das tabelas e séries temporais dos índices DY.

O grafo do *full sample* é posicionado pelo algoritmo de Fruchterman-Reingold. Para os painéis comparativos entre subperíodos (pré-COVID, COVID-19, aperto da Selic e crise Americanas), as coordenadas dos nós são calculadas uma única vez sobre o *full sample* e mantidas fixas em todos os painéis. Essa escolha é metodológica, garantindo que as diferenças visuais entre painéis reflitam reconfiguração da topologia da rede, e não reposicionamento dos nós.

A representação em grafo é um instrumento heurístico e comunicativo. As escolhas de *threshold*, algoritmo de *layout* e paleta de cores afetam a percepção visual, mas não os coeficientes estimados. Toda a inferência sobre transmissão de risco entre as instituições é conduzida a partir das tabelas e das séries temporais dos índices DY e das métricas de centralidade definidos na Subseção 3.2.

4 Resultados

Referências

ACEMOGLU, Daron; OZDAGLAR, Asuman; TAHBAZ-SALEHI, Alireza. Systemic Risk and Stability in Financial Networks. **American Economic Review**, v. 105, n. 2, p. 564–608, fev. 2015. ISSN 0002-8282. DOI: 10.1257/aer.20130456. Acesso em: 26 abr. 2026.

ALLEN, Franklin; GALE, Douglas. Financial Contagion. **The Journal of Political Economy**, v. 108, n. 1, p. 1–33, 2000. JSTOR: 3038241.

ALLEN, Franklin; GALE, Douglas. Optimal Financial Crises. **The Journal of Finance**, [American Finance Association, Wiley], v. 53, n. 4, p. 1245–1284, 1998. ISSN 0022-1082. JSTOR: 117401. Acesso em: 26 abr. 2026.

ANDERSEN, Torben G.; BOLLERSLEV, Tim; DIEBOLD, Francis X.; EBENS, Heiko. The Distribution of Realized Stock Return Volatility. **Journal of Financial Economics**, v. 61, n. 1, p. 43–76, jul. 2001. ISSN 0304-405X. DOI: 10.1016/S0304-405X(01)00055-1. Acesso em: 12 jun. 2026.

ANDERSEN, Torben G.; BOLLERSLEV, Tim; DIEBOLD, Francis X.; LABYS, Paul. Modeling and Forecasting Realized Volatility. **Econometrica**, [Wiley, Econometric Society], v. 71, n. 2, p. 579–625, 2003. ISSN 0012-9682. JSTOR: 3082068. Acesso em: 12 jun. 2026.

ANDO, Tomohiro; GREENWOOD-NIMMO, Matthew; SHIN, Yongcheol. Quantile Connectedness: Modeling Tail Behavior in the Topology of Financial Networks. **Management Science**, INFORMS, v. 68, n. 4, p. 2401–2431, 2022. Acesso em: 17 jun. 2026.

ANTONAKAKIS, Nikolaos; CHATZIANTONIOU, Ioannis; GABAUER, David. Refined Measures of Dynamic Connectedness Based on Time-Varying Parameter Vector Autoregressions. **Journal of Risk and Financial Management**, Multidisciplinary Digital Publishing Institute, v. 13, n. 4, p. 84, abr. 2020. ISSN 1911-8074. DOI: 10.3390/jrfm13040084. Acesso em: 16 maio 2026.

BARUNÍK, Jozef; KŘEHLÍK, Tomáš. Measuring the Frequency Dynamics of Financial Connectedness and Systemic Risk. **Journal of Financial Econometrics**, Oxford University Press, v. 16, n. 2, p. 271–296, 2018. Acesso em: 17 jun. 2026.

BOSTANCI, Gorkem; YILMAZ, Kamil. How Connected Is the Global Sovereign Credit Risk Network? **Journal of Banking & Finance**, Elsevier, v. 113, n. 100, 2020. Acesso em: 21 maio 2026.

CAJUEIRO, Daniel O.; TABAK, Benjamin M. The Role of Banks in the Brazilian Interbank Market: Does Bank Type Matter? **Physica A Statistical Mechanics and its Applications**, Elsevier, v. 387, p. 6825–6836, dez. 2008. ISSN 0378-4371. DOI: 10.1016/j.physa.2008.08.031. Acesso em: 16 maio 2026.

CHATZIANTONIOU, Ioannis; GABAUER, David. EMU Risk-Synchronisation and Financial Fragility through the Prism of Dynamic Connectedness. **The Quarterly Review of Economics and Finance**, v. 79, p. 1–14, fev. 2021. ISSN 1062-9769. DOI: 10.1016/j.qref.2020.12.003. Acesso em: 16 maio 2026.

CONT, Rama; MOUSSA, Amal; SANTOS, Edson B. Network Structure and Systemic Risk in Banking Systems. In: FOUQUE, Jean-Pierre; LANGSAM, Joseph A. (ed.). **Handbook on Systemic Risk**. 1. ed. [S. l.]: Cambridge University Press, maio 2013. p. 327–368. ISBN 978-1-107-02343-7 978-1-139-15118-4. DOI: 10.1017/CBO9781139151184.018. Acesso em: 22 abr. 2026.

DEMIRER, Mert *et al.* Estimating Global Bank Network Connectedness. **Journal of Applied Econometrics**, v. 33, n. 1, p. 1–15, jan. 2018. ISSN 0883-7252, 1099-1255. DOI: 10.1002/jae.2585. Acesso em: 27 maio 2026.

DIAMOND, Douglas W.; DYBVIG, Philip H. Bank Runs, Deposit Insurance, and Liquidity. **Journal of Political Economy**, University of Chicago Press, v. 91, n. 3, p. 401–419, 1983. Acesso em: 26 abr. 2026.

DIEBOLD, Francis X.; INOUE, Atsushi. Long Memory and Regime Switching. **Journal of Econometrics**, v. 105, n. 1, p. 131–159, nov. 2001. ISSN 0304-4076. DOI: 10.1016/S0304-4076(01)00073-2. Acesso em: 12 jun. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Better to Give than to Receive: Predictive Directional Measurement of Volatility Spillovers. **International Journal of Forecasting**, v. 28, n. 1, p. 57–66, jan. 2012. ISSN 0169-2070. DOI: 10.1016/j.ijforecast.2011.02.006. Acesso em: 22 abr. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Equity Market Spillovers in the Americas, 2011.

DIEBOLD, Francis X.; YILMAZ, Kamil. Measuring Financial Asset Return and Volatility Spillovers, With Application to Global Equity Markets. **Economic Journal**, v. 119, p. 158–171, jan. 2009. DOI: 10.1111/j.1468-0297.2008.02208.x.

DIEBOLD, Francis X.; YILMAZ, Kamil. On the Network Topology of Variance Decompositions: Measuring the Connectedness of Financial Firms. **Journal of Econometrics**, v. 182, n. 1, p. 119–134, set. 2014. ISSN 0304-4076. DOI: 10.1016/j.jeconom.2014.04.012. Acesso em: 22 abr. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. **On the Past, Present, and Future of the Diebold-Yilmaz Approach to Dynamic Network Connectedness**. [S. l.]: arXiv, jan. 2023. DOI: 10.48550/arXiv.2211.04184. arXiv: 2211.04184 [econ.EM]. Acesso em: 20 maio 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Trans-Atlantic Equity Volatility Connectedness: U.S. and European Financial Institutions, 2004–2014. **Journal of Financial Econometrics**, Oxford University Press, v. 14, n. 1, p. 81–127, 2016. Acesso em: 26 abr. 2026.

GABAUER, David. **ConnectednessApproach: Connectedness Approach**. [S. l.]: Comprehensive R Archive Network, mar. 2022. p. 1.0.4. DOI: 10.32614/CRAN.package.ConnectednessApproach. Acesso em: 26 maio 2026.

GLASSERMAN, Paul; YOUNG, H. Peyton. Contagion in Financial Networks. **Journal of Economic Literature**, v. 54, n. 3, p. 779–831, set. 2016. ISSN 0022-0515. DOI: 10.1257/jel.20151228. Acesso em: 22 abr. 2026.

GLASSERMAN, Paul; YOUNG, H. Peyton. How Likely Is Contagion in Financial Networks?, 2014.

KOOP, Gary; PESARAN, M. Hashem; POTTER, Simon M. Impulse Response Analysis in Nonlinear Multivariate Models. **Journal of Econometrics**, v. 74, n. 1, p. 119–147, set. 1996. ISSN 0304-4076. DOI: 10.1016/0304-4076(95)01753-4. Acesso em: 8 maio 2026.

MORITZ, Steffen; BARTZ-BEIELSTEIN, Thomas. imputeTS: Time Series Missing Value Imputation in R. **The R Journal**, v. 9, n. 1, p. 207, 2017. ISSN 2073-4859. DOI: 10.32614/RJ-2017-009. Acesso em: 26 maio 2026.

MOURA, Bruna Gonçalves Fonseca; FERREIRA, Bruno Pérez; CORRÊA, Ana Carolina Costa. Brazilian Banks Risk-Taking and Systemic Risk. **The Quarterly Review of Economics and Finance**, Elsevier, v. 98, n. 100, 2024. Acesso em: 26 abr. 2026.

PESARAN, H. Hashem; SHIN, Yongcheol. Generalized Impulse Response Analysis in Linear Multivariate Models. **Economics Letters**, v. 58, n. 1, p. 17–29, jan. 1998. ISSN 01651765. DOI: 10.1016/S0165-1765(97)00214-0. Acesso em: 22 abr. 2026.

ROGERS, L. C. G.; SATCHELL, S. E. Estimating Variance From High, Low and Closing Prices. **The Annals of Applied Probability**, Institute of Mathematical Statistics, v. 1, n. 4, p. 504–512, 1991. ISSN 1050-5164. JSTOR: 2959703. Acesso em: 18 set. 2026.

SILVA, Mairton Nogueira; PASSOS, Marcelo De Oliveira *et al.* Dynamic Connectivity and Contagion Risk Among Bank Stocks in Brazil. **Computational Economics**, Springer & Society for Computational Economics, v. 66, n. 2, p. 1513–1543, 2025. Acesso em: 26 abr. 2026.

SILVA, Thiago Christiano; DE SOUZA, Sergio Rubens Stancato; TABAK, Benjamin Miranda. Network Structure Analysis of the Brazilian Interbank Market. **Emerging Markets Review**, v. 26, p. 130–152, mar. 2016. ISSN 15660141. DOI: 10.1016/j.ememar.2015.12.004. Acesso em: 22 abr. 2026.

SILVA, Walmir; KIMURA, Herbert; SOBREIRO, Vinicius Amorim. An Analysis of the Literature on Systemic Financial Risk: A Survey. **Journal of Financial Stability**, v. 28, p. 91–114, fev. 2017. ISSN 1572-3089. DOI: 10.1016/j.jfs.2016.12.004. Acesso em: 22 abr. 2026.

YANG, Dennis; ZHANG, Qiang. Drift-Independent Volatility Estimation Based on High, Low, Open, and Close Prices. **The Journal of Business**, University of Chicago Press, v. 73, n. 3, p. 477–91, 2000. DOI: 10.1086/209650. Acesso em: 7 maio 2026.