Guilherme Henrique De Nardi

Conectividade e Spillovers de Volatilidade no Sistema Bancário Brasileiro: Uma Análise de Redes via Diebold-Yilmaz

Osasco
2026

Guilherme Henrique De Nardi

Conectividade e Spillovers de Volatilidade no Sistema Bancário Brasileiro: Uma Análise de Redes via Diebold-Yilmaz

Monografia apresentada ao Departamento de Economia da Universidade Federal de São Paulo como requisito parcial para obtenção do grau de Bacharel em Ciências Econômicas, sob orientação do Prof. Dr. Diego Ferreira.

Universidade Federal de São Paulo
Escola Paulista de Política, Economia e Negócios

Orientador: Diego Ferreira

Osasco
2026

Sumário

1	**INTRODUÇÃO**	**3**
2	**REVISÃO BIBLIOGRÁFICA**	**5**
3	**METODOLOGIA**	**11**
3.1	**Base de Dados**	**11**
3.2	**Topologia de Redes via Diebold-Yilmaz**	**21**
3.3	**Visualização de Redes**	**27**
4	**RESULTADOS**	**29**
4.1	**Pré-tratamento dos dados**	**29**
4.2	**Propriedades das séries**	**29**
4.3	**Seleção dos fatores de esquecimento**	**31**
4.4	**Conectividade estática do painel principal**	**31**
4.5	**Conectividade dinâmica**	**32**
A	**JANELA ROLANTE**	**34**
	Referências	**35**

1 Introdução

O sistema bancário brasileiro enfrentou, entre 2017 e 2026, um período marcado por choques de naturezas distintas como uma pandemia global, o ciclo de aperto monetário do pós-pandemia, e episódios de instabilidade idiossincrática como o caso Americanas. Esses episódios oferecem um cenário propício para investigar como o risco se propaga entre instituições financeiras, e se essa propagação muda de intensidade e direção conforme a natureza do choque. Risco sistêmico refere-se à possibilidade de que o colapso ou fragilização de uma instituição se propague para o restante do sistema, ameaçando sua estabilidade como um todo. A literatura sobre redes financeiras estabelece que a arquitetura de interconexão que confere resiliência ao sistema em momentos de normalidade pode se converter em um mecanismo de amplificação dependendo da magnitude de um choque (Acemoglu; Ozdaglar; Tahbaz-Salehi, 2015). Compreender essa dinâmica, não apenas a magnitude mas também a evolução ao longo do tempo, é relevante tanto para a literatura quanto para a formulação de política macroprudencial.

Mensurar a propagação de forma contínua e baseada em dados públicos é o objetivo central deste trabalho, que investiga a rede de spillovers de volatilidade entre os principais bancos brasileiros ao longo do recorte 2017-2026. A pergunta que orienta a pesquisa é como a estrutura da rede entre essas instituições evolui ao longo do tempo e reage a eventos macroeconômicos e idiossincráticos. A investigação busca não apenas identificar a existência de interdependência entre as instituições, mas compreender mudanças na topologia da rede com variações no grau de conectividade e na importância relativa de cada instituição em diferentes contextos econômicos.

A hipótese do trabalho é de que a intensidade de spillovers se eleva em períodos identificáveis instabilidade financeira, como a pandemia do COVID-19, o ciclo de aperto monetário e episódios idiossincráticos, refletindo maior interconectividade e potencial de propagações de choques, em linha com a dinâmica prevista pela literatura teórica de redes financeiras (Acemoglu; Ozdaglar; Tahbaz-Salehi, 2015; Allen; Gale, 2000)

A abordagem adotada baseia-se no modelo de Diebold e Yilmaz (2009, 2012, 2014), que utiliza um vetor autorregressivo (VAR) e a decomposição generalizada da variância dos erros de previsão (GFEVD) para mensurar a interdependência entre variáveis, construindo uma matriz de spillovers interpretável como a matriz de adjacência de uma rede complexa dirigida e ponderada. A variável-alvo é a volatilidade, não os retornos, estimada por um estimador de amplitude (range-based) que combina o componente de Rogers e Satchell (1991), independente de tendência intradiária, com um termo de retorno overnight, capturando o fato de que decisões do Comitê de Política Monetária e resultados trimestrais são divulgados após o fechamento do pregão. A amostra é estratificada por tipo de controle de capital, porte e modelo de negócio, e organizada em dois painéis aninhados: um painel principal, com maior alcance temporal, e um painel de extensão que incorpora o Banco Pan, cuja relação de controle com o BTG Pactual permite testar diretamente se o vínculo societário entre instituições se traduz em maior

comovimento de volatilidade.

Embora a metodologia de Diebold-Yilmaz tenha sido amplamente aplicada a mercados financeiros internacionais e a índices de ações de economias emergentes, sua aplicação ao nível de instituições bancárias individuais no Brasil permanece escassa. Os estudos brasileiros de risco sistêmico predominantemente dependem de dados de balanço ou de exposições interbancárias sigilosas, mantidas pelo Banco Central e inacessíveis à comunidade científica, o que compromete a comparabilidade dos resultados e restringe análises em escala ampla e frequência elevada. Este trabalho preenche essa lacuna em três frentes. Primeiro, estratifica a amostra por tipo de controle, modelo de negócio e porte, tornando a heterogeneidade institucional do sistema bancário brasileiro explícita na análise de spillovers. Segundo, compara explicitamente o ranking de transmissão (TO_i, Equação 3.9) derivado dos *spillovers* com a segmentação prudencial do Banco Central do Brasil, testando se uma metodologia baseada inteiramente em dados públicos de mercado é capaz de aproximar a classificação regulatória das instituições consideradas sistemicamente relevantes. Terceiro, testa se atributos compartilhados por pares de instituições como vínculo de controle societário, tipo de controle e porte organizam a topologia de rede por meio de uma regressão diádica com efeitos fixos de emissor e receptor, abordagem mais robusta do que comparações agregadas por categoria nominal de controle.

O restante do trabalho está organizado em três capítulos. O Capítulo 2 revisa a literatura sobre risco sistêmico, conectividade em redes financeiras e a evolução metodológica do framework de Diebold-Yilmaz, situando as contribuições deste trabalho no debate. O Capítulo 3 detalha a metodologia: a base de dados e os critérios de construção dos dois painéis amostrais, a estimação da volatilidade, a especificação do VAR e da GFEVD, o procedimento dinâmico via TVP-VAR, a regressão diádica e os procedimentos de visualização de redes. O Capítulo 4 apresenta e discute os resultados, incluindo as considerações finais do trabalho.

2 Revisão Bibliográfica

A noção de risco sistêmico na literatura econômica remonta a trabalhos clássicos que destacam a fragilidade inerente das instituições financeiras. O modelo de corridas bancárias de Diamond e Dybvig (1983) estabelece que bancos são estruturalmente vulneráveis a choques de confiança, nos quais a retirada simultânea de depósitos pode levar ao colapso de instituições solventes. Essa fragilidade não é somente individual, mas de natureza sistêmica, na medida em que a falência de uma instituição pode desencadear efeitos de contágio sobre o restante do sistema financeiro, configurando o caráter sistêmico do risco bancário. A instabilidade pode emergir de forma endógena relacionada à estrutura do próprio sistema, trabalhos subsequentes como o de Allen e Gale (1998) reforçam essa perspectiva. Embora esses modelos estabeleçam os fundamentos da fragilidade financeira, ainda apresentam limitações por operarem sob hipóteses simplificadoras, nas quais a heterogeneidade entre agentes e a complexidade das interações financeiras são limitadas. Como resultado, esses modelos oferecem pouca orientação sobre como a arquitetura das conexões financeiras influencia a propagação de choques em sistemas contemporâneos.

A crise financeira global de 2008 representa um ponto de inflexão na pesquisa sobre risco sistêmico em instituições financeiras. A importância da arquitetura de rede já havia sido demonstrada em Allen e Gale (2000) de modo que as estruturas incompletas de reivindicações interbancárias se mostram mais propensas a episódios de contágio do que estruturas completas. Contudo, foi somente após o colapso de instituições de importância sistêmica que a fragilidade do sistema financeiro e a topologia da rede financeira passaram a ocupar posição central no debate acadêmico e regulatório.

Por meio de uma análise bibliométrica extensa, Silva, Kimura e Sobreiro (2017) documentam essa virada: a literatura sobre estabilidade financeira evoluiu para focar na topologia das redes interbancárias, identificando o contágio via interconectividade como a principal fonte de fragilidade sistêmica contemporânea. A interconectividade cria canais para o contágio e amplificação de choques no sistema financeiro, sendo este o ponto principal de Glasserman e Young (2015) que a identificam como um dos principais determinantes de crises financeiras recentes.

A mesma arquitetura de rede que promove resiliência em tempos de normalidade é a que propaga contágio em momentos de estresse severo. Essa natureza dual é formalizada em Acemoglu, Ozdaglar e Tahbaz-Salehi (2015). O regime de propagação depende, portanto, da magnitude do choque inicial. Uma rede altamente conectada atua como um mecanismo de absorção de choques para choques de baixa magnitude, mas se converte em mecanismo de amplificação e propagação sistêmica quando os choques ultrapassam um limiar crítico. Essa dinâmica de limiar é formalizada de maneira mais ampla pela literatura de cascatas em redes financeiras. Os mecanismos pelos quais as perdas se propagam em cascata é mapeado

extensamente em Glasserman e Young (2016), distinguindo canais de contágio diretos e indiretos. A probabilidade e magnitude de uma cascata dependem conjuntamente da topologia de rede e da distribuição de exposições, fortalecendo a percepção de que a mensuração empírica de conectividade é condição necessária para a avaliação do risco sistêmico.

A literatura converge na ideia de que a interconectividade é elemento central para a compreensão do risco sistêmico. Diverge, porém, quanto à sua mensuração empírica, especialmente em contextos nos quais a estrutura da rede não é diretamente observável. Como resultado, grande parte da literatura depende de proxies indiretas que aproximam imperfeitamente a topologia da rede, ou de bases granulares de acesso restrito mantidas por reguladores, o que compromete a comparabilidade dos resultados e restringe análises empíricas em escala ampla e frequência elevada.

O problema da mensuração indireta encontra uma solução metodológica no spillover index, proposto por Diebold e Yilmaz (2009) a partir de dados de mercado de acesso público. A metodologia utiliza um modelo de vetores autorregressivos (VAR) e a decomposição da variância dos erros de previsão para gerar um índice agregado de conectividade, mensurando a interdependência entre ativos ou mercados financeiros. Em outras palavras, o índice quantifica a parcela da variância de uma variável atribuível a choques nas demais, em contraposição à parcela atribuível à própria. Por meio da representação MA(∞) do VAR e da decomposição de Cholesky, os autores decompõem a variância do erro de previsão em parcelas de variância própria (*own variance shares*), decorrentes de choques na própria variável, e parcelas de variância cruzada (*cross variance shares*). O *spillover index* é construído pela soma das contribuições de choques originados em i sobre o erro de previsão de j (para todo $i \neq j$), normalizada pela variância total do sistema.

Entretanto, o *spillover index* original apresentava duas limitações principais sendo a sensibilidade à ordem das variáveis na decomposição de variância e a dificuldade em identificar a origem e o destino dos choques. Para superar esses desafios, uma refinação da metodologia foi apresentada em Diebold e Yilmaz (2012) ao adotar a Decomposição Generalizada da Variância dos Erros de Previsão (GFEVD), proposta originalmente por Koop, Pesaran e Potter (1996) e Pesaran e Shin (1998). Ao adotar a GFEVD, os autores eliminaram o problema inerente à ordenação das variáveis, característica da decomposição de Cholesky, possibilitando uma identificação invariante da topologia de transmissão de risco. O refinamento metodológico permitiu, ainda, a introdução do conceito de *net spillover*, definido como a diferença entre a contribuição que uma variável transmite ao sistema e aquela que dela recebe, classificando cada variável como transmissora ou receptora líquida de volatilidade. O balanço histórico de Diebold e Yilmaz (2023) consolida o modelo de conectividade dinâmica como a base para a análise macroprudencial, demonstrando que os *spillovers* de mercado refletem fielmente a topologia de transmissão do risco sistêmico.

A matriz de conectividade resultante da GFEVD admite, ainda, uma leitura sob a ótica da teoria das redes como a matriz de adjacência de uma rede complexa, intuição formalizada

em Diebold e Yilmaz (2014). Diferentemente da maior parte da literatura aplicada de redes financeiras, que analisa apenas a existência de conexões entre instituições, a estrutura derivada da GFEVD configura um grafo direcionado e ponderado. A natureza direcionada da rede captura a dinâmica de assimetria do risco financeiro, dado que a contribuição de i para a variância de j não coincide, em geral, com a contribuição inversa.

Dessa estrutura, Diebold e Yilmaz (2014) derivam métricas de conectividade com correspondência direta nas medidas fundamentais da teoria de grafos. O conceito de *from-degree*, que mede a conectividade total recebida pelo nó (equivalente ao *in-degree* em teoria dos grafos), funciona como indicador de vulnerabilidade da variável a choques transmitidos pelos demais elementos do sistema. Em contrapartida, o *to-degree*, equivalente ao *out-degree*, mede a conectividade transmitida pelo nó aos demais e identifica os elementos com maior potencial de propagação sistêmica. O índice agregado de conectividade do sistema, por sua vez, sintetiza a densidade da interdependência da rede, sendo equivalente conceitualmente ao grau médio normalizado de um grafo ponderado.

A abordagem de janelas móveis (*rolling-window*), embora permita capturar a evolução temporal da conectividade, impõe uma limitação relevante em que os parâmetros do modelo são recalculados em janelas fixas e discretas, o que pode obscurecer transições graduais na estrutura da rede. A alternativa é estimar os parâmetros de forma contínua, sem a definição de uma janela fixa. É o que fazem Antonakakis, Chatziantoniou e Gabauer (2020) e Chatziantoniou e Gabauer (2021) ao propor a estimação do índice de conectividade via modelos de parâmetros variantes no tempo (*Time-Varying Parameter VAR* - TVP-VAR). Essa extensão metodológica preserva a interpretabilidade do *framework* de Diebold-Yilmaz, ao mesmo tempo em que oferece uma representação mais contínua e sensível da dinâmica de transmissão de risco, tornando-se especialmente adequada para a análise de sistemas financeiros sujeitos a choques abruptos e regimes variantes. A escolha entre rolling-window e TVP-VAR envolve um *trade-off* entre simplicidade interpretativa e suavidade na captura de transições de regime. A abordagem de janelas móveis, embora consiga atenuar efeitos de memória longa característicos de séries de volatilidade financeira não é suficiente para identificar episódios de elevação da conectividade associados já que data defasadamente os movimentos de acordo com o tamanho especificado da janela. Por esse motivo, o TVP-VAR é adotado como especificação principal neste trabalho, com a janela móvel mantida apenas como comparação com a convenção da literatura de referência.

A representação espectral da decomposição da variância permite também analisar os spillovers no domínio da frequência. O risco sistêmico tem dinâmicas distintas. A conectividade gerada em altas frequências reflete o processamento rápido de informações no curto prazo em momentos de calmaria, enquanto a conectividade gerada em baixa frequências sinaliza choques persistentes e mudanças estruturais nas expectativas dos agentes, sendo esse o ponto central de Baruník e Křehlík (2018). O modelo exige um horizonte de aproximação e uma extensão amostral longos para que o algoritmo de Fourier mapeie as baixas frequências com precisão. Essas escolhas introduzem o risco de sofrer com *overfitting* e problemas de graus de liberdade,

especialmente em janelas amostrais mais curtas.

Também é possível estender a abordagem para o domínio quantílico conforme proposto em Ando, Greenwood-Nimmo e Shin (2022). Os autores demonstraram empiricamente que a transmissão de choques e o risco de contágio são fenômenos de cauda, se apresentam virtualmente ausentes na mediana e se expandem de forma severa em períodos de estresse. Dada a natureza assimétrica e não-linear da conectividade financeira, os modelos baseados na média condicional tendem a subestimar o potencial de contágio sistêmico em momentos de crise. A estimação depende de dados de densidade alta e amostras maiores, o que inviabiliza sua aplicação. A dinâmica temporal de janelas móveis consegue capturar a transição do sistema para a cauda uma vez que a média condicional é dominada por observações extremas em momento de crise, além de ser computacionalmente acessível e estável.

O *spillover index* foi utilizado para analisar a volatilidade dos retornos da rede de instituições financeiras norte-americanas e europeias no período 2004–2014 e caracterizar a dinâmica da conectividade ao longo da crise financeira de 2008 em Diebold e Yilmaz (2016). Os autores argumentam que, no período pós-2008, a transmissão de volatilidade se tornou mais bidirecional, com aumento expressivo da influência das instituições europeias sobre o mercado norte-americano. Além disso, os autores demonstram que, após o colapso do Lehman Brothers, a crise financeira teria adquirido caráter efetivamente global. O estudo evidencia o aprofundamento das conexões entre instituições financeiras em períodos de estresse, corroborando a interpretação de Acemoglu, Ozdaglar e Tahbaz-Salehi (2015) de que a interconectividade que estabiliza em normalidade amplifica choques sob estresse severo.

Para os mercados das Américas Diebold e Yilmaz (2011) analisam empiricamente os *spillovers* de volatilidade entre cinco mercados de ações: EUA, México, Chile, Argentina e Brasil. Os autores identificam que, embora as economias centrais dominem a transmissão em momentos de estresse agudo, as economias latino-americanas exibem fluxos de transmissão regional não desprezíveis. Para o Brasil, especificamente, os resultados indicam que o país não opera como receptor passivo de volatilidade, mas atua como *hub* regional de propagação de volatilidade, refletindo sua centralidade econômica na América Latina. Esse achado motiva investigações mais aprofundadas sobre como a posição do Brasil na rede de *spillovers* se comporta em períodos posteriores, marcados por choques idiossincráticos domésticos.

O risco soberano oferece outro campo de aplicação do *framework* de Diebold-Yilmaz, mensurando os *spillovers* de volatilidade de *credit default swaps* (CDS) entre economias emergentes e avançadas, foco central em Bostanci e Yilmaz (2020). O estudo evidencia que a rede de spillovers é altamente integrada e que os mercados emergentes (incluindo o Brasil) assumiram um papel central como transmissores líquidos de volatilidade financeira no período pós-crise. A unidade de análise, porém, é o risco soberano agregado. O CDS reflete o risco de crédito do país como um todo e não a estrutura de transmissão entre instituições individualmente. Permanece em aberto se essa centralidade do Brasil como transmissor líquido se reproduz ou se inverte quando a rede é decomposta nas instituições que a compõem. O país pode ser transmissor líquido

agregado enquanto, internamente, alguns bancos atuam como receptores.

No entanto, a combinação de choques observados ao longo de 2017-2026 têm uma natureza distinta daquela observada nos sistemas avançados analisados em Diebold e Yilmaz (2016). Uma pandemia global, um ciclo abrupto de aperto monetário e episódios de instabilidade como a fraude contábil da Americanas sugerindo que a estrutura de rede de *spillovers* brasileira possui determinantes distintos daqueles observados nas economias avançadas. O mercado interbancário brasileiro apresenta estrutura concentrada. As primeiras evidências empíricas em Cajueiro e Tabak (2008) de topologia do mercado interbancário brasileiro sob a ótica das redes complexas demonstram que o sistema exibe elevada heterogeneidade estruturada em torno de *money centers*, em que o porte e o tipo de controle do capital determinam a centralidade da instituição na rede.

Evidências para o caso brasileiro também sugerem que a estrutura do sistema interbancário brasileiro apresenta uma elevada concentração de conectividade em um número reduzido de instituições de importância sistêmica. Em Silva, De Souza e Tabak (2016), os autores caracterizam a rede interbancária brasileira por meio de medidas de teoria de redes. O artigo documenta que o mercado interbancário brasileiro possui uma estrutura de *core-periphery*, em que o núcleo é composto por um pequeno grupo de bancos grandes e altamente conectados, e a periferia, por um grande número de bancos menores que se conectam ao núcleo, mas raramente entre si próprios. O estudo, contudo, depende de dados granulares e sigilosos mantidos pelo Banco Central do Brasil, inacessíveis ao público e à comunidade científica.

O mesmo problema de dependência de dados sigilosos aparece em Cont, Moussa e Santos (2013), que propõem o *Contagion Index*, a perda esperada do sistema condicional à inadimplência de uma instituição em um período de estresse macroeconômico a partir de uma base de exposições cedidas pelo Banco Central do Brasil. Os achados dialogam com Silva, De Souza e Tabak (2016) já que o sistema exibe topologia *scale-free*, em que a maioria dos nós possui poucas conexões, enquanto alguns nós, conhecidos como *hubs*, concentram um grande número de conexões. Sob essa topologia, a concentração da exposição e do risco sistêmico em poucos nós centrais favorece a propagação de perdas em cascata, com choques macroeconômicos atuando como mecanismo central de amplificação. A pesquisa, no entanto, tem seu mecanismo de transmissão modelado exclusivamente pelo balanço, ignorando o canal dos preços de mercado pelo qual a incerteza sobre uma instituição se transmite às demais antes que qualquer exposição materialize a perda.

O ΔCoVaR aplicado ao caso brasileiro por Moura, Ferreira e Corrêa (2024), com dados de mercado, demonstra que a contribuição marginal para o risco sistêmico no Brasil está ligada ao perfil de tomada de risco das instituições. Ainda que o estudo evidencie empiricamente que a vulnerabilidade de balanços é relevante para o risco sistêmico, o método não captura a direcionalidade e a topologia da rede em tempo real. Embora o ΔCoVaR identifique a magnitude do impacto potencial de uma instituição sobre o sistema, ele falha em mapear os canais de transmissão e o efeito cascata das interações, tornando necessária uma abordagem complementar baseada em spillovers que desenhe a arquitetura das interações.

Em síntese, as evidências disponíveis para o caso brasileiro partem, predominantemente, de dados sigilosos do Banco Central do Brasil. Essa dependência cria uma lacuna metodológica que exige abordagens complementares fundamentadas em dados públicos de mercado, como os *spillovers* de volatilidade capturados pela metodologia de Diebold-Yilmaz, que permitam uma análise dinâmica, transparente e em alta frequência da conectividade sistêmica, dispensando o acesso a bases sigilosas.

A lacuna de dados públicos encontra resposta parcial em Silva, Passos *et al.* (2025), que visa resolver investigando a conectividade através de dados de ações bancárias listadas no Ibovespa. Utilizando um modelo TVP-VAR e complementando o estudo com métricas de redes complexas, os autores buscam entender como o contágio financeiro se propaga através da rede brasileira. O estudo demonstra que a estrutura de transmissão de volatilidade entre bancos brasileiros é instável e sensível a choques macroeconômicos e políticos, atingindo picos superiores a 50% em períodos de instabilidade política e econômica com Bradesco, Banco do Brasil e Itaú operando como os nós centrais na transmissão de choques. Contudo, o estudo define seu universo amostral por critério de liquidez, sem estratificar as instituições, o que limita a capacidade de caracterizar como a heterogeneidade institucional do sistema bancário influencia a estrutura de transmissão de risco.

O presente trabalho propõe-se a preencher essas lacunas em três frentes. Primeiro, estratifica a amostra por tipo de controle (público, privado nacional e estrangeiro), modelo de negócio (varejo, investimento, atacado e consumo) e porte, tornando a heterogeneidade institucional do sistema bancário brasileiro explícita na análise de *spillovers*. Segundo, vai além das métricas reportadas por Silva, Passos *et al.* (2025) ao comparar explicitamente o ranking de trasmissão sistêmica (TO_i) derivado dos *spillovers* com a segmentação prudencial de D-SIBs publicada pelo Banco Central do Brasil (Conselho Monetário Nacional, 2017), testando se uma metodologia baseada em dados públicos de mercado é capaz de aproximar a classificação regulatória. Terceiro, testa se atributos compartilhados pelos pares de instituições organizam a topologia da rede, por meio de uma regressão diádica com efeitos fixos de emissor e de receptor (Subseção 3.2), abordagem raramente reportada em estudos de *spillovers* bancários brasileiros.

3 Metodologia

Esta seção apresenta as escolhas metodológicas do trabalho em três subseções. A Subseção 3.1 descreve a base de dados, os critérios de seleção da amostra, a construção das séries de volatilidade e os procedimentos de tratamento dos dados. A Subseção 3.2 apresenta a topologia de redes via Diebold-Yilmaz, incluindo a especificação do VAR, a identificação por decomposição generalizada da variância e os índices de spillover. A Subseção 3.3 detalha a visualização de redes e a interpretação econômica das métricas de centralidade.

3.1 Base de Dados

Seleção da amostra

A amostra é composta por oito instituições bancárias com ações negociadas na B3 entre 2017 e 2026. A composição foi definida de modo a maximizar três dimensões de heterogeneidade relevantes para o estudo de risco sistêmico: (i) *tipo de controle*, abrangendo bancos privados nacionais, público federal, público estadual e privados estrangeiros; (ii) *perfil de negócio*, cobrindo varejo massificado, banco de investimento, atacado corporativo e crédito ao consumo; e (iii) *porte*, incluindo tanto *large caps* quanto *mid caps*.

A amostra contempla as oito instituições bancárias com ações listadas na B3 que reúnem, em conjunto, representatividade sistêmica e diversidade de perfis de controle e modelo de negócio. Itaú Unibanco (ITUB4) e Bradesco (BBDC4) figuram como os dois maiores bancos privados nacionais, funcionando como *hubs* centrais da rede de conectividade. O Banco do Brasil (BBAS3), como maior instituição pública federal, captura a exposição do sistema a políticas governamentais. O Santander (SANB11) representa o principal canal de transmissão de choques internacionais, na condição de maior banco estrangeiro do país. O BTG Pactual (BPAC11), maior banco de investimento independente da América Latina, contribui com um perfil de *wholesale* distinto dos bancos de varejo tradicionais. O Banrisul (BRSR6), único banco público estadual com liquidez suficiente para o estudo, introduz uma dimensão regional (Rio Grande do Sul) à amostra. O ABC Brasil (ABCB4), por sua vez, diversifica tanto o tipo de controle (privado estrangeiro) quanto o modelo de negócio (*wholesale* puro). Por fim, o Banco Pan (BPAN4) representa o segmento de bancos médios de varejo, com a particularidade de manter relação societária com o BTG Pactual, o que pode gerar *spillovers* par-a-par relevantes entre as duas instituições.

Três instituições com presença relevante no mercado de capitais foram deliberadamente excluídas. O Banco BMG (BMGB4) apresenta perfil de negócio redundante com o Banco Pan, ambos concentrados em crédito consignado e varejo, além de liquidez em bolsa materialmente inferior. A B3 S.A. (B3SA3) não é uma instituição bancária, mas uma infraestrutura de mercado;

sua inclusão alteraria a natureza do estudo. BB Seguridade (BBSE3) e Porto Seguro (PSSA3) são seguradoras e, portanto, sua inclusão deslocaria o foco do sistema bancário para uma rede financeira mais ampla, comprometendo a comparabilidade com as Instituições Financeiras Sistemicamente Importantes Domésticas (D-SIBs) designadas pelo Banco Central do Brasil (BCB).

O recorte temporal de cada instituição não é uma escolha discricionária, mas decorre diretamente do critério de liquidez de um volume financeiro diário inferior a R$ 100 mil. Seis das oito instituições - ITUB4, BBDC4, BBAS3, SANB11, BRSR6 e ABCB4 - nunca ficam abaixo desse piso ao longo de toda a base disponível, desde 2014. As duas exceções definem as fronteiras efetivas da amostra. O BPAC11 só passa a negociar de forma continuamente líquida a partir de 18/08/2017 - antes disso, a ação, listada em fevereiro de 2017, ainda está em fase de formação de *book*. O BPAN4, por sua vez, só se torna continuamente líquido a partir de 16/01/2019. No terceiro trimestre de 2018, por exemplo, o papel permanece abaixo do piso de liquidez em 44 dos 63 pregões do período, com média de apenas 48 negócios diários. O painel de extensão começa em 01/01/2019 e o único pregão abaixo do piso, 15/01/2019, é imputado.

Essas duas fronteiras, determinadas pelos dados, geram naturalmente dois painéis aninhados, apresentados na Tabela 1. O painel principal (N = 7) exclui o Banco Pan e cobre o período de outubro de 2017 a maio de 2026, o maior alcance temporal possível dado o critério de liquidez das sete instituições restantes. O painel de extensão (N = 8) inclui o Banco Pan e cobre janeiro de 2019 a outubro de 2025.

Tabela 1 – Painéis amostrais com fronteiras determinadas pelos dados

Painel	Janela	Observações	Papel
N = 7 (sem Banco Pan)	10/2017 a 09/2026	2.234	Principal
N = 8 (com Banco Pan)	01/2019 a 10/2025	1.689	Extensão

O vínculo societário BTG-Pan

A hipótese de que o vínculo societário produz co-movimento de volatilidade não pode ser testada no painel principal, pela razão evidente de que nele não há nenhum par de instituições ligadas por controle. Recorre-se, por isso, ao painel de oito instituições, único em que o par BTG e Banco Pan está presente. A restrição não decorre de escolha metodológica, e sim do fato de que, no sistema bancário brasileiro listado, esse é o único vínculo dessa natureza disponível no período.

A Tabela 2 apresenta os coeficientes da regressão diádica com indicadoras por par específico (Equação 3.19), estimada em corte único sobre o painel de extensão. Dois resultados se destacam. O par que compartilha vínculo de controle efetivo, BTG e Pan, apresenta o segundo maior coeficiente da tabela (+5,94 pontos percentuais, $p < 0{,}0001$), e o par classificado apenas sob a etiqueta nominal de "privado estrangeiro"(ABC Brasil e Santander), duas instituições sem

qualquer proximidade de porte ou modelo de negócio apresenta o único coeficiente negativo (–2,29 pontos percentuais, $p = 0{,}011$). Esse padrão contraria a hipótese puramente categórica de que compartilhar um rotulo de classificação produz, por si só, conectividade adicional, e pode até estar associado a menos.

A leitura não se resume, porém, a ideia de que vínculo societário organiza a rede, categoria nominal não. O par Itaú e Bradesco, os dois maiores bancos privados nacionais da amostra e sem qualquer vínculo de controle entre si, também apresenta coeficiente elevado (+6,24 pontos percentuais, $p < 0{,}0001$). Como a regressão já controla separadamente pelo efeito de ambos serem instituições de grande porte (+4,10 pontos percentuais, $p < 0{,}0001$), o coeficiente de Itaú–Bradesco representa um comovimento adicional, específico do par, que não é explicado nem pela propensão geral de cada banco a transmitir e receber risco, nem pelo porte. Duas explicações são compatíveis com os dados sendo a primeira em relação ao vínculo de controle societário testado nesta subseção e a segunda sobre a proximidade de modelo de negócio e de exposição a choques regulatórios e macroeconômicos comuns aos dois maiores bancos de varejo do país, mecanismo distinto mas igualmente capaz de gerar comovimento além do que porte e propensão geral já explicam. Os dados aqui disponíveis não permitem distinguir entre as duas hipóteses para o par Itaú–Bradesco, na ausência de um vínculo de controle a testar. O achado central da subseção permanece. O mecanismo de controle societário é suficiente para gerar comovimento da mesma magnitude que a maior proximidade de porte e modelo de negócio da amostra, mas não é o único mecanismo capaz de fazê-lo.

Tabela 2 – Regressão diádica com indicadoras por par específico (painel de extensão, corte único)

Indicadora	Coeficiente (p.p.)	t	p
Bradesco e Itaú (privados nacionais)	6,24	8,44	$< 0{,}0001$
BTG e Pan (vínculo societário)	5,94	7,24	$< 0{,}0001$
Banco do Brasil e Banrisul (estatais)	0,47	0,93	0,361
ABC Brasil e Santander ("estrangeiros")	–2,29	–2,67	0,011
Ambos de grande porte	4,10	5,34	$< 0{,}0001$

Fonte: elaboração própria.

A robustez desse resultado não depende de um único corte amostral. A Tabela 3 reestima a mesma regressão a cada mês, totalizando 82 cortes ao longo do painel de extensão, e resume a série de coeficientes resultante pela média, pela proporção de meses com sinal positivo e por um teste t da média contra zero. O par BTG–Pan mantém sinal positivo em 74 dos 82 cortes (90%), com média de 5,26 pontos percentuais ($t = 12{,}8$); o par Itaú–Bradesco e a indicadora de porte mantêm sinal positivo em todos os 82 cortes; o par ABC Brasil–Santander mantém sinal negativo na grande maioria deles (apenas 17 de 82 positivos). A evidência não repousa, portanto, sobre o resultado pontual de uma única estimação, mas sobre a repetição do padrão de sinal ao longo de quase sete anos de dados mensais.

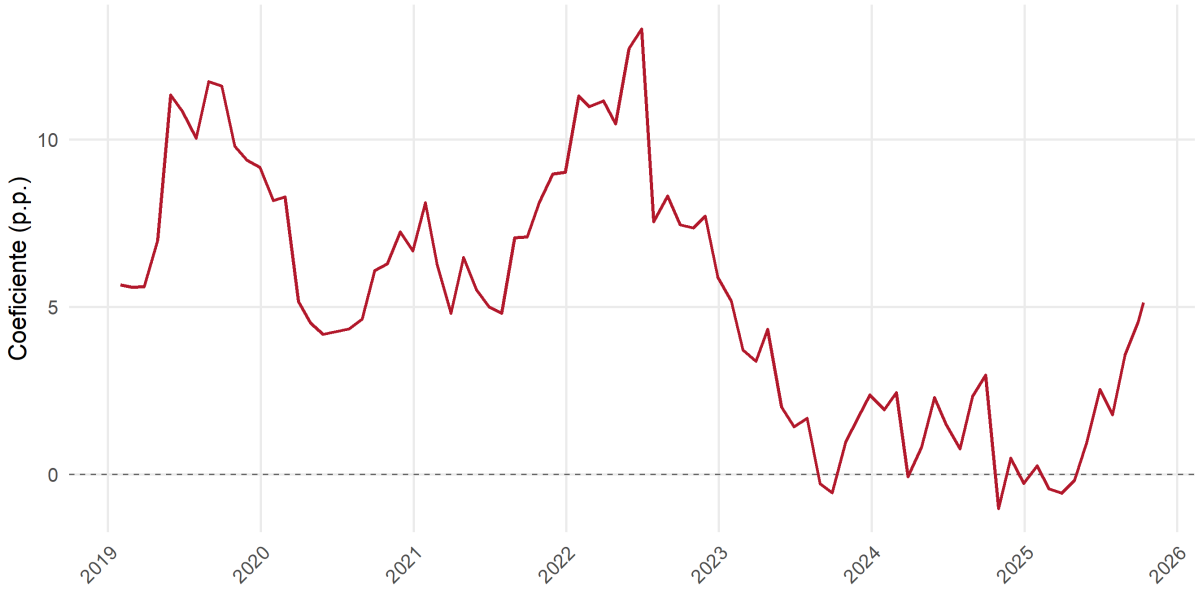
Tabela 3 – Regressão diádica por par específico - extensão temporal (82 cortes mensais)

Indicadora	Média (p.p.)	Sinal positivo	t	p
Bradesco e Itaú (privados nacionais)	6,44	82/82	19,66	$< 0{,}0001$
BTG e Pan (vínculo societário)	5,26	74/82	12,8	$< 0{,}0001$
Banco do Brasil e Banrisul (estatais)	0,68	49/82	3,29	0,0015
ABC Brasil e Santander ("estrangeiros")	–1,21	17/82	–5,98	$< 0{,}0001$
Ambos de grande porte	3,51	82/82	22,95	$< 0{,}0001$

Fonte: elaboração própria.

A Figura 1 mostra a evolução do coeficiente do par BTG–Pan ao longo do tempo, e não apenas sua média. A série atinge seu valor máximo em 2022 (9,52 pontos percentuais em média anual), um ano após o BTG Pactual assumir o controle pleno do Banco Pan, em maio de 2021, ao adquirir a totalidade da participação até então detida pela Caixa Econômica Federal e encerrar o controle compartilhado que mantinha desde 2011 [1] O intervalo de um ano entre a consolidação do controle e o pico do coeficiente é compatível com uma reprecificação gradual do vínculo entre as duas instituições pelo mercado, e não com um efeito instantâneo. Após o pico, o coeficiente cai de forma contínua até 2024 (1,19 ponto percentual, o mínimo da série), voltando a subir em 2025 (1,77 pontos percentuais) em um movimento que coincide com o anúncio de incorporação total do Pan pelo BTG, em outubro de 2025.

Figura 1 – Coeficiente da regressão diádica: BTG-Pan



Fonte: elaboração própria.

A conclusão da subseção decorre desse mesmo anúncio. Até 13/10/2025, os retornos

[1] BANCO PAN. *Nossa História*. Relações com Investidores, 2021. Disponível em: `https://ri.bancopan.com.br/show.aspx?idCanal=98FuehC2XKrWRMgsqA5Tpw==&linguagem=pt`. Acesso em: 21/09/2026.

diários do Pan e do BTG apresentam correlação moderada, em torno de 0,39 a 0,43 em janelas comparáveis antes e depois do anúncio. Essa correlação do período pós-anúncio tomado como um todo, contudo, mistura duas fases distintas do processo: as semanas iniciais, em que a conclusão do negócio ainda dependia de aprovações societárias e regulatórias, e as semanas finais, em que a relação de troca fixa entre os papéis (0,2128 *unit* do BTG por ação do Pan) já era essencialmente certa. A correlação móvel de curto prazo revela essa transição: nos últimos 10, 30 e 60 pregões de negociação do Pan antes da deslistagem, a correlação converge para 0,96, 0,97 e 0,97, respectivamente. Esse movimento é consistente com o mecanismo de arbitragem esperado quando a conclusão da fusão se torna praticamente certa. Não foi possível identificar, entre os comunicados ao mercado disponíveis, um fato relevante específico na data exata em que essa convergência se inicia (28/10/2025, identificada por correlação móvel de curta janela), que antecede em cerca de seis semanas a aprovação em assembleia geral (09/12/2025), os marcos formais do processo documentados publicamente ocorrem majoritariamente depois dessa data.

Esse fato cumpre dois papéis na subseção. Primeiro, explica por que o painel de extensão se encerra em 13/10/2025: com a correlação entre os dois papéis convergindo para próximo de 1 ao final do processo, as duas séries deixam de ser distinguíveis para fins de decomposição de variância, e a estimação do VAR se tornaria numericamente degenerada se estendida além desse ponto. Segundo, e mais importante, confirma que se o vínculo de controle societário aproxima o comportamento de duas ações, a fusão completa deveria aproximá-las ao limite já que é o vinculo societário mais forte possível. Foi exatamente o que se observou. O resultado que a subseção buscou estabelecer com efeitos fixos e dados mensais ao longo de sete anos é confirmado através desse fato.

O resultado desta subseção não é levado ao painel principal de sete instituições porque o vínculo societário se encerrou no mundo real com a incorporação. Em contrapartida, é o painel principal que permite alcançar o regime de conectividade elevada de 2026, fora do alcance do painel de extensão.

Construção das séries de volatilidade

Justificativa da variável-alvo

A variável-alvo deste estudo é a volatilidade das ações dos bancos selecionados, e não os retornos. Essa escolha é motivada pelo próprio objeto de análise: importância sistêmica, no sentido adotado pelo BCB para a designação de D-SIBs, é um conceito de segundo momento e refere-se à capacidade de uma instituição propagar *estresse* pelo sistema financeiro, não apenas retornos. Spillovers de volatilidade capturam precisamente essa dimensão e são tipicamente maiores, mais informativos e mais robustos a mudanças de regime do que spillovers de retornos (Diebold; Yilmaz, 2009). Ademais, a janela amostral escolhida concentra episódios cujos efeitos se manifestaram primordialmente na volatilidade como COVID-19, ciclo de aperto da Selic em 2022 e fraude contábil da Americanas em 2023. Por fim, a presença de *mid caps* na amostra,

cujo volume de negociação é irregular, recomenda o uso de medidas *range-based*, mais robustas ao ruído de microestrutura do que retornos diários *close-to-close*.

Estimador Rogers-Satchell

A volatilidade é mensurada por um estimador *range-based* de um único dia, sem sobreposição entre observações consecutivas, que combina o componente de Rogers e Satchell (1991), independente de drift intradiário, com um termo de retorno *overnight*:

$$\hat{\sigma}_t^2 = \hat{o}_t^2 + \widehat{RS}_t, \tag{3.1}$$

onde

$$\hat{o}_t^2 = \left[\log\left(\frac{O_t}{C_{t-1}}\right)\right]^2, \tag{3.2}$$

$$\widehat{RS}_t = \log\left(\frac{H_t}{C_t}\right)\log\left(\frac{H_t}{O_t}\right) + \log\left(\frac{L_t}{C_t}\right)\log\left(\frac{L_t}{O_t}\right). \tag{3.3}$$

Aqui H_t, L_t, O_t e C_t denotam os preços máximo, mínimo, de abertura e de fechamento no dia t, respectivamente, e C_{t-1} o preço de fechamento do pregão anterior. Diferentemente de estimadores de amplitude baseados em janela móvel de n dias, as Equações 3.1–3.3 produzem uma estimativa de variância por pregão, sem exigir médias amostrais calculadas sobre uma janela: cada observação é independente das demais, eliminando por construção qualquer sobreposição de dados entre estimativas consecutivas. A variável efetivamente utilizada nas estimações é $y_t = \log\big(\max\big(\hat{\sigma}_t\sqrt{252},\ 10^{-8}\big)\big)$, onde $\hat{\sigma}_t = \sqrt{\hat{\sigma}_t^2}$ é anualizado pela convenção de 252 pregões por ano, seguindo a mesma prática de anualização adotada por Diebold e Yilmaz (2012) e Diebold e Yilmaz (2014), e o piso numérico evita indeterminação logarítmica nos raros pregões de variância estimada nula. A transformação logarítmica aproxima a distribuição dos choques de um padrão gaussiano, facilitando a inferência no VAR.

Tabela 4 – Pregões tratados como ausentes por $\hat{\sigma}_t^2 < 10^{-8}$

Instituição	Painel N = 7	Painel N = 8
ITUB4	0	0
BBDC4	0	0
BBAS3	1	1
SANB11	3	2
BPAC11	1	1
BRSR6	3	3
ABCB4	6	4
BPAN4	–	2

Fonte: elaboração própria. Inclui variâncias negativas, produto de ruído numérico.

A independência em relação ao *drift* significa que o estimador não confunde tendência com volatilidade, ou seja, se o preço apenas sobe ou apenas desce ao longo do dia, o movimento

é lido como tendência e não como oscilação. Num dia que abre no fechamento da véspera e na máxima e cai até fechar na mínima, $O_t = C_{t-1}$ anula o termo *overnight* (Equação 3.2), $H_t = O_t$ anula o primeiro produto de (3.3) e $L_t = C_t$ anula o segundo, resultando em $\hat{\sigma}_t^2 = 0$ embora o papel tenha caído vários pontos percentuais. Como a variável é o logaritmo da volatilidade, tais pregões geram valores em torno de -11 (média próxima de $-1{,}4$), a mais de 14 desvios-padrão da média, que distorcem o VAR e elevam a curtose em excesso de algumas séries. Por isso, todo pregão com $\hat{\sigma}_t^2 < 10^{-8}$ é tratado como ausente e imputado pelo filtro de Kalman (item 6 do protocolo de tratamento). A regra é pouco intrusiva: nenhuma instituição perde mais de seis pregões, cerca de 0,3% da amostra (Tabela 4).

Por que Rogers-Satchell e não estimadores alternativos?

O estimador de Garman-Klass ignora a variação *overnight* (C_{t-1} a O_t), tratando o ativo como se nada ocorresse fora do pregão. Para o sistema bancário brasileiro no período isso é particularmente problemático já que decisões do Comitê de Política Monetária (Copom) são divulgadas após o fechamento do mercado, resultados trimestrais são publicados *after-market* e dados macroeconômicos norte-americanos chegam durante a tarde-noite no horário de Brasília. No painel principal, o termo *overnight* (Equação 3.2) responde por 16% (ABC Brasil) a 34% (Banco do Brasil) da soma de $\hat{\sigma}_t^2$ ao longo da amostra, conforme a instituição, de modo que descartar essa componente subestimaria sistematicamente a volatilidade efetiva. Adicionalmente, Garman-Klass assume *drift* intradiário nulo, o que o torna positivamente viesado em janelas com tendência marcada como em março de 2020 (COVID-19) e janeiro de 2023 (Americanas). O estimador de Parkinson utiliza apenas os extremos (H_t e L_t), sendo estritamente menos eficiente do que Garman-Klass, que incorpora O_t e C_t.

A volatilidade realizada (RV) intradiária exigiria dados de *tick*, indisponíveis abertamente para o período amostral completo. Mesmo com acesso a dados de alta frequência, medições a 5 minutos produzem viés por *bid-ask bounce*, e as correções técnicas associadas fogem do escopo deste trabalho. A presença de *mid caps* na amostra agrava o problema de modo que dias sem negociação contínua geram zeros artificiais que inflam RV. A abordagem GARCH(1,1) introduziria uma camada paramétrica adicional antes do VAR, gerando duas etapas de modelagem encadeadas que complicam a interpretação e a robustez, além de operar apenas com retornos *close-to-close*, descartando a informação intradiária que torna os estimadores *range-based* mais eficientes.

A escolha inicial desse trabalho recaiu sobre o estimador de Yang e Zhang (2000), que combina os mesmos componentes de *drift* independente e retorno *overnight* em uma janela móvel de n dias. Essa escolha, no entanto, não resiste ao diagnóstico dos resíduos. A janela de $n = 21$ dias, recalculada a cada pregão, faz com que observações consecutivas compartilhem $n - 1$ dos n dias da janela, essa estrutura induz autocorrelação na série de log-volatilidade e não reflete a dinâmica econômica real, a diferença passa a ser o dia que entra e o dia que sai da janela a cada atualização. Essa autocorrelação se propaga diretamente para os resíduos do

VAR estimado sobre a série, violando a hipótese de ruído branco que sustenta avalidade da decomposição de variância subsequente, os critérios de seleção de defasagem chegam a cair de forma descontínua no número de defasagens correspondente ao tamanho da janela, sinal de que o modelo está simplesmente reconhecendo a memória embutida no estimador e não capturando dinâmica genuína dos dados.

A sobreposição, contudo, é autoinfligida pela escolha de uma janela de múltiplos dias. Para Diebold e Yilmaz (2012), Diebold e Yilmaz (2014) e Demirer *et al.* (2018), os autores empregam estimadores de amplitude de um único dia e a janela não é utilizada em suas aplicações de referência do *framework* de conectividade. A substituição por Rogers-Satchell com termo *overnight* preserva os dois pilares da escolha original, a cobertura do risco *overnight* e a independência em relação ao *drift*, sem herdar a estrutura de médias móveis induzida pela janela e sem exigir os primeiros $n - 1$ pregões de cada série como aquecimento. Os testes de estacionariedade são conduzidos sobre a série resultante dessa substituição.

Período amostral

Os dois painéis descritos concentram, entre si, os principais episódios de estresse do sistema financeiro brasileiro recente, cujos efeitos sobre a volatilidade bancária são centrais para a análise dinâmica: a crise da COVID-19 e os *circuit breakers* de março de 2020, o ciclo de aperto monetário da Selic iniciado em março de 2021, a fraude contábil da Americanas (janeiro de 2023), o estresse fiscal do segundo semestre de 2024 e, no painel principal, o regime de conectividade elevada observado no primeiro semestre de 2026. A Tabela 5 apresenta os principais eventos de *drift* identificados na janela amostral.

Tabela 5 – Principais eventos de *drift* na janela amostral

Período	Direção	Causa
Mar./2020	Negativo extremo	*Crash* COVID-19
Abr.–dez./2020	Positivo persistente	Recuperação pós-*crash*
Jan.–set./2022	Negativo persistente	Aperto da Selic
Jan.–mar./2023	Negativo (ITUB4, BBDC4)	Fraude Americanas
Ago.–dez./2023	Positivo (*large caps*)	Início do ciclo de corte da Selic
Mai./2024 (BRSR6)	Negativo idiossincrático	Enchentes no Rio Grande do Sul
Out.–dez./2024	Negativo persistente	Crise fiscal pós-pacote governamental
Jan.–abr./2025	Negativo (sistema)	Tarifas Trump pós-posse
Mai.–dez./2025	Positivo (*large caps*)	Expansão de *spread* bancário
Jan.–mai./2026[2]	Positivo persistente	[causa a confirmar]

[2]Episódio identificável apenas no painel principal. O painel de extensão, limitado a outubro de 2025, não o alcança.

Tratamento dos dados

Os procedimentos de tratamento são aplicados na seguinte ordem.

1. Extração dos dados

Os dados OHLC de todas as oito instituições foram obtidos da base ComDinheiro. Os preços são fornecidos já ajustados retroativamente por proventos considerando dividendos, juros sobre capital próprio, bonificações, *splits*, *inplits* e cisões (*spin-offs*). A escolha por essa fonte foi motivada por duas limitações identificadas. Primeiro, o Banco Pan (BPAN4) deixou de ser negociado ao final de janeiro de 2026, em decorrência da incorporação ao BTG Pactual, o que tornou o *ticker* indisponível em provedores que não mantêm o histórico de ativos descontinuados. Segundo, o ajuste automático de provedores como o Yahoo Finance corrige dividendos e *splits* mas não cisões. A série de ITUB4, por exemplo, registraria uma queda de aproximadamente -18% em 04/10/2021 decorrente da incorporação da XPart, veículo que detinha a participação do Itaú na XP Inc., pela XP, com a entrega de BDRs da XP aos acionistas do Itaú, em um movimento que não reflete volatilidade de mercado real[3]. Caso não corrigido, o movimento entraria no estimador como um termo *overnight* de magnitude desproporcional, uma observação espúria.

2. Verificação de consistência

Antes da estimação da volatilidade, os dados OHLC são submetidos a verificações de consistência lógica: $H_t \geq L_t$, $H_t \geq O_t$, $H_t \geq C_t$, $L_t \leq O_t$, $L_t \leq C_t$ e $O_t, C_t > 0$. Violações indicam erros de digitação ou de *parsing* no provedor de dados, que produziriam valores inválidos (`NaN`) no cálculo dos logaritmos do estimador

3. Filtro de liquidez

Dias com volume financeiro inferior a R$ 100 mil são marcados como `NA`. Para as *mid caps* ABCB4, BPAN4 e BRSR6, dias com volume muito reduzido produzem *ranges* ($H_t - L_t$) que refletem o *bid-ask spread* da microestrutura, e não a volatilidade efetiva do ativo. Observações filtradas são tratadas na etapa de imputação.

4. Tratamento de *outliers*

Retornos extremos são identificados pelo escore padronizado $z_t = (r_t - \bar{r})/\hat{\sigma}_r$ calculado sobre os retornos *close-to-close*, sendo $|z_t| > 5$ o critério de sinalização. Para cada observação sinalizada, verifica-se: se múltiplas instituições registram retorno extremo na mesma data, o

[3]ITAÚ UNIBANCO HOLDING S.A. *Fato Relevante: aprovada a incorporação da XPart pela XP Inc. em 01.10.2021*. São Paulo, 2 out. 2021. Disponível em: `https://www.prnewswire.com/news-releases/fato-relevante-aprovada-a-incorporacao-da-xpart-pela-xp-inc-em-01-10-2021-814119261.html`. Acesso em: 15/10/2026.

evento é classificado como real e mantido; se apenas uma instituição apresenta retorno extremo sem notícia identificável, a observação é conferida em fonte alternativa. Como referência, 12 e 16 de março de 2020 (*circuit breakers* da COVID-19) e 12 de janeiro de 2023 (Americanas, restrito a ITUB4 e BBDC4) são eventos reais e são preservados na amostra.

5. Estimação da volatilidade

A volatilidade Rogers-Satchell é estimada conforme as equações 3.1–3.3 e anualizada, de modo que $y_t = \log\big(\max(\hat{\sigma}_t\sqrt{252},\, 10^{-8})\big)$, com $\hat{\sigma}_t = \sqrt{\hat{\sigma}_t^2}$. Todo pregão com $\hat{\sigma}_t^2 < 10^{-8}$ é tratado como ausente e segue para a imputação da etapa 6: o pregão que anda numa única direção recebe variância zero do estimador, como explicado na descrição do estimador, acima. No painel principal, a regra remove de zero (ITUB4 e BBDC4) a seis pregões (ABCB4) por instituição, no máximo 0,3% da amostra (Tabela 4). O piso de 10^{-8} da fórmula permanece como salvaguarda numérica e, depois da regra, não é acionado.

6. Alinhamento e imputação

As séries de log-volatilidade são alinhadas por data de pregão, formando um painel $T \times 7$ e $T \times 8$ no caso do painel de extensão. Dias em que todas as séries apresentam `NA` (finais de semana, feriados) são excluídos. Observações isoladas com `NA` decorrentes do filtro de liquidez ou de erros de provedor são imputadas por filtro de Kalman aplicado a um modelo ARIMA selecionado automaticamente[4]. A integridade do painel é verificada ao final pela ausência de qualquer `NA` residual.

A qualidade dos dados de entrada é verificada antes de qualquer estimação, pelo protocolo descrito na seção. Vale registrar, desde já, o resultado dessa verificação, porque ele não é trivial: a checagem de consistência lógica do OHLC ($H_t \geq L_t, O_t, C_t$; $L_t \leq O_t, C_t$; $O_t, C_t > 0$) inicialmente sinalizava dezenas de violações por instituição — número alto o suficiente para sugerir um problema real na base. A investigação dessas violações, porém, revelou que a totalidade delas era ruído de ponto flutuante da ordem de 10^{-9}, originado no cálculo do fator de ajuste retroativo por proventos da base ComDinheiro: dias em que o papel fechou exatamente na máxima do pregão ($H_t = C_t$, matematicamente), mas a representação em ponto flutuante das duas colunas diverge na décima casa decimal, disparando a comparação estrita como se fosse uma inconsistência real. Após a introdução de uma tolerância numérica de 10^{-6} nenhuma violação genuína de consistência OHLC permanece em nenhuma das oito séries. O filtro de liquidez, por sua vez, afeta um único pregão, o do Banco Pan em 15/01/2019 (volume de R$ 72 mil e 67 negócios); nenhum pregão do painel principal é filtrado. Os números completos do pré-tratamento, por painel, são reportados no Capítulo 4.

[4] O filtro de Kalman fornece estimativas ótimas de estados não observados em um modelo de espaço de estados, minimizando o erro quadrático médio da predição. Neste contexto, o modelo ARIMA descreve a dinâmica autorregressiva da série de log-volatilidade e o filtro utiliza toda a informação disponível, observações passadas e futuras (*smoother*) para imputar os valores ausentes. Para detalhes, consultar Moritz e Bartz-Beielstein (2017).

Propriedades estatísticas

A estacionariedade de cada série de log-volatilidade é testada por meio do teste de Dickey-Fuller Aumentado (ADF), do teste KPSS, do teste DF-GLS, do teste de Phillips-Perron e do teste de Zivot-Andrews, aplicados ao painel já imputado pelo filtro de Kalman, o mesmo que entra no VAR. Em todas as séries, o ADF rejeita a raiz unitária e o KPSS rejeita a estacionariedade (Capítulo 4). Esse padrão é típico de séries de log-volatilidade, que frequentemente exibem memória longa (Andersen; Bollerslev; Diebold; Ebens, 2001; Andersen; Bollerslev; Diebold; Labys, 2003; Diebold; Inoue, 2001).

Para caracterizar essa memória, estima-se o parâmetro de integração fracionária d de cada série pelo estimador de Geweke e Porter-Hudak (1983). No painel principal, $\hat{d}$ situa-se entre 0,45 e 0,6 com erro-padrão de cerca de 0,11.

Valores de d entre 0 e 1 indicam que a série não é nem $I(0)$ nem $I(1)$. É por isso que o ADF e o KPSS rejeitam ao mesmo tempo. O primeiro tem a raiz unitária como hipótese nula e o segundo, a estacionariedade, e nenhum dos dois contempla o caso intermediário. Com $\hat{d}$ em torno de 0,5, as séries estão na fronteira entre o regime estacionário ($d < 0{,}5$) e o não estacionário com reversão à média ($0{,}5 \leq d < 1$).

Por esse motivo, as séries não são diferenciadas. Um VAR em níveis é uma aproximação de memória curta a um processo de memória longa, prática padrão na literatura de conectividade Diebold-Yilmaz; diferenciar a série eliminaria a persistência que o índice busca medir.

A presença de autocorrelação serial e de heterocedasticidade condicional é verificada pelos testes de Ljung-Box e ARCH-LM, respectivamente.

3.2 Topologia de Redes via Diebold-Yilmaz

Especificação do VAR

Seja $\mathbf{y}_t = (y_{1t}, \ldots, y_{Nt})'$ o vetor $N \times 1$ das séries de log-volatilidade, com $N = 7$ no painel principal e $N = 8$ no painel de extensão. O modelo VAR de ordem p é:

$$\mathbf{y}_t = \mathbf{c} + \sum_{i=1}^{p} \mathbf{\Phi}_i \, \mathbf{y}_{t-i} + \boldsymbol{\varepsilon}_t, \qquad \boldsymbol{\varepsilon}_t \sim (\mathbf{0},\, \mathbf{\Sigma}), \tag{3.4}$$

onde $\mathbf{c}$ é um vetor de constantes, $\mathbf{\Phi}_i$ são matrizes $N \times N$ de coeficientes autorregressivos e $\boldsymbol{\varepsilon}_t$ é um vetor de inovações com matriz de covariância $\mathbf{\Sigma}$. Os parâmetros são estimados por Mínimos Quadrados Ordinários (MQO) equação a equação, estimador implementado pelo pacote `ConnectednessApproach` (Gabauer, 2022).

A especificação estática adota $p = 2$ defasagens, selecionadas pelo critério de informação de Schwarz (BIC) sobre o painel completo, em concordância com a convenção de referência da literatura (Diebold; Yilmaz, 2009, 2012).

A condição de estabilidade do VAR exige que todas as raízes do polinômio característico $\det\big(\mathbf{I}_N - \mathbf{\Phi}_1 z - \cdots - \mathbf{\Phi}_p z^p\big) = 0$ encontrem-se fora do círculo unitário no plano complexo, equivalentemente, que os módulos dos autovalores da matriz companheira sejam estritamente menores que um. Essa condição garante que o VAR admita a representação de média móvel de ordem infinita $\mathbf{y}_t = \sum_{h=0}^{\infty} \mathbf{A}_h \, \boldsymbol{\varepsilon}_{t-h}$, utilizada na decomposição de variância subsequente.

Identificação via GFEVD

A identificação dos spillovers baseia-se na *Generalized Forecast Error Variance Decomposition* (GFEVD) de Pesaran e Shin (1998). Dado o horizonte de previsão τ, a fração da variância do erro de previsão de i atribuída a choques em j é:

$$\theta_{ij}^{\tau} = \frac{\sigma_{jj}^{-1} \sum_{h=0}^{\tau-1} \big(\mathbf{e}_i' \, \mathbf{A}_h \, \mathbf{\Sigma} \, \mathbf{e}_j\big)^2}{\sum_{h=0}^{\tau-1} \mathbf{e}_i' \, \mathbf{A}_h \, \mathbf{\Sigma} \, \mathbf{A}_h' \, \mathbf{e}_i}, \tag{3.5}$$

onde σ_{jj} é o j-ésimo elemento diagonal de $\mathbf{\Sigma}$ e $\mathbf{e}_i$ é o i-ésimo vetor canônico. A identificação generalizada de Pesaran e Shin distingue-se da decomposição de Cholesky por não impor ordenação recursiva, eliminando a sensibilidade dos resultados a permutações da ordem do VAR. Como contrapartida, as linhas da matriz $\mathbf{\Theta}^{\tau} = [\theta_{ij}^{\tau}]$ não somam necessariamente um. Aplica-se normalização linha-a-linha:

$$\tilde{\theta}_{ij}^{\tau} = \frac{\theta_{ij}^{\tau}}{\sum_{j=1}^{N} \theta_{ij}^{\tau}}, \tag{3.6}$$

de modo que $\sum_{j=1}^{N} \tilde{\theta}_{ij}^{\tau} = 1$ e $\sum_{i,j=1}^{N} \tilde{\theta}_{ij}^{\tau} = N$ por construção. O horizonte é fixado em $\tau = 10$ dias úteis, seguindo a convenção de Diebold e Yilmaz (2009), Diebold e Yilmaz (2012) e Diebold e Yilmaz (2014).

Índices de *spillover*

A partir da matriz normalizada $\tilde{\mathbf{\Theta}}^{\tau}$, definem-se os índices de conectividade de Diebold e Yilmaz (2012): o índice de conectividade total, os índices direcionais de transmissão e recepção de choques, o índice líquido por instituição e o índice líquido par-a-par.

$$\text{TCI} = \frac{1}{N} \sum_{\substack{i,j=1 \\ i \neq j}}^{N} \tilde{\theta}_{ij}^{\tau} \times 100, \tag{3.7}$$

$$\text{FROM}_i = \sum_{\substack{j=1 \\ j \neq i}}^{N} \tilde{\theta}_{ij}^{\tau} \times 100, \tag{3.8}$$

$$\text{TO}_j = \sum_{\substack{i=1 \\ i \neq j}}^{N} \tilde{\theta}_{ij}^{\tau} \times 100, \tag{3.9}$$

$$\text{NET}_i = \text{TO}_i - \text{FROM}_i, \tag{3.10}$$

$$\text{NET}_{ij} = \tilde{\theta}_{ji}^{\tau} - \tilde{\theta}_{ij}^{\tau}. \tag{3.11}$$

O *Total Connectedness Index* (TCI) em (3.7) mede a fração média da variância do erro de previsão de cada banco explicada por choques nos demais. FROM_i (3.8) quantifica a receptividade sistêmica de i; TO_j (3.9) mede a transmissão sistêmica de j; NET_i (3.10) classifica as instituições como transmissores líquidos ($\text{NET}_i > 0$) ou receptores líquidos ($\text{NET}_i < 0$); NET_{ij} (3.11) captura a direção líquida do fluxo de risco entre cada par de instituições.

No entanto, o nível do TCI tem um limite de interpretação. Ele não é comparável entre estudos com número diferente de instituições. O índice mede quanto da variância de cada banco vem dos demais e, com mais instituições no sistema, cada banco passa a ter mais fontes de choque externo e a parcela que vem dele mesmo encolhe, de modo que o índice sobe apenas porque N aumentou, sem que haja mais contágio. Nos dados deste trabalho, o TCI da amostra completa, estimado sobre subconjuntos aleatórios de 2, 4, 6 e 7 bancos do painel principal, é em média de 18%, 38%, 49% e 53%, respectivamente. Por isso, o nível do TCI deste trabalho não é comparado ao de outros estudos. Por isso, o nível do TCI deste trabalho não é comparado ao de outros estudos, inclusive ao de Silva, Passos *et al.* (2025), que trabalha com 14 bancos. Comparam-se a convenção de estimação (TVP-VAR) e a dinâmica do índice ao longo do tempo, isto é, em que períodos ele se eleva. Pela mesma razão, o nível também não é comparável entre os dois painéis deste trabalho ($N = 7$ e $N = 8$).

Para além dos índices direcionais propostos por Diebold e Yilmaz (2012), este trabalho incorpora um conjunto de métricas de teoria de redes, centralidade de autovetor e PageRank, calculadas sobre o grafo de conectividade $G = (V, E, W)$ definido na Seção 3.3. Essa incorporação constitui uma contribuição adicional do trabalho. Com $N = 7$ e um grafo em que todos os nós se ligam a todos, porém, essas medidas coincidem com os índices de primeira ordem. A ordenação dos bancos pelo PageRank é idêntica à ordenação por FROM_i e, no grafo invertido, à ordenação por TO_j (correlação de postos de Spearman igual a 1 nos quatro casos, o mesmo valendo para a centralidade de autovetor). Trata-se de um resultado sobre o limite dessas medidas em redes pequenas e densas onde elas não acrescentam informação aos índices direcionais e são reportadas apenas como verificação. O contraste central deste trabalho é a confrontação entre o ranking de transmissão sistêmica (TO_i, Equação 3.9) e a segmentação prudencial do Banco Central do Brasil. A Resolução CMN nº 4.553/2017 (Conselho Monetário Nacional, 2017) estabelece a segmentação das instituições financeiras em cinco segmentos (S1

a S5) conforme porte e atividade internacional; a Resolução CMN nº 4.958/2021, art. 8º, §2º (Conselho Monetário Nacional, 2021), condiciona a exigência do Adicional de Importância Sistêmica de Capital Principal ($\text{ACP}_{\text{Sistêmico}}$) às instituições enquadradas no S1, tornando o S1 o critério normativo brasileiro funcionalmente equivalente à designação de D-SIB adotada em outras jurisdições. As métricas de centralidade de autovetor e PageRank, calculadas na direção de entrada, capturam uma dimensão distinta de receptividade recursiva a choques de bancos já centrais e são reportadas como complementares, não como critério do confronto regulatório.

Especificação dinâmica: TVP-VAR com fatores de esquecimento

A especificação dinâmica principal deste trabalho estima os coeficientes do VAR e a covariância dos choques como variantes no tempo, em vez de recalculá-los em janelas móveis fixas e discretas. Nessa última abordagem, o índice de conectividade estimado em uma data t reflete uma média retrospectiva sobre os W dias anteriores, de modo que o pico de conectividade de um episódio de crise é datado na borda direita da janela, quando esta está mais preenchida por observações do episódio e não na data em que o episódio de fato ocorre.

Seja $z_t = (y'_{t-1}, \ldots, y'_{t-p}, 1)'$ o vetor de regressores no instante t e $Z_t = I_N \otimes z'_t$. O modelo (3.4) é reescrito em forma de espaço de estados, com o vetor de coeficientes β_t (dimensão $N(Np+1)$, correspondente ao empilhamento de $\Phi_1, \ldots, \Phi_p, c$ de todas as equações) evoluindo como um passeio aleatório:

$$y_t = Z_t \beta_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \Sigma_t), \tag{3.12}$$

$$\beta_t = \beta_{t-1} + u_t, \quad u_t \sim N(0, Q_t). \tag{3.13}$$

A estimação exata de (3.12)–(3.13) por métodos bayesianos completos, como em Primiceri (2005) e no corrigendum de Del Negro e Primiceri (2015), exige amostragem MCMC (algoritmo de Carter-Kohn) recomputada a cada iteração, sendo computacionalmente inviável para um estado de dimensão $N(Np+1)$ superior a cem, como é o caso deste trabalho, e originalmente concebida para sistemas de poucas variáveis. A alternativa adotada, proposta por Koop e Korobilis (2013) e aplicada ao contexto de conectividade por Antonakakis, Chatziantoniou e Gabauer (2020) e Chatziantoniou e Gabauer (2021), substitui a covariância de estado Q_t e a covariância dos choques Σ_t por estimativas recursivas governadas por dois fatores de esquecimento, κ_1 e κ_2, dispensando a amostragem MCMC.

O fator κ_1 governa a velocidade de deriva dos coeficientes. Em vez de estimar Q_t diretamente, impõe-se $Q_t = (\kappa_1^{-1} - 1)\, P_{t-1|t-1}$, onde $P_{t|t}$ é a covariância do estado no filtro de Kalman. Essa imposição faz a etapa de predição do filtro colapsar em:

$$P_{t|t-1} = P_{t-1|t-1} + Q_t = \frac{1}{\kappa_1} P_{t-1|t-1}. \tag{3.14}$$

Com $\kappa_1 = 1$, tem-se $Q_t = 0$, os coeficientes não se movem e o modelo colapsa no VAR de parâmetros constantes da especificação estática. Com $\kappa_1 < 1$, a covariância do estado é inflada a

cada período, abrindo espaço para deriva: uma observação de j períodos atrás entra com peso κ_1^j na estimativa filtrada de β_t, de modo que a amostra efetiva de memória do filtro é da ordem de $(1-\kappa_1)^{-1}$ observações.

O fator κ_2 governa a velocidade de adaptação da covariância dos choques, atualizada por média móvel exponencial dos resíduos do próprio filtro:

$$\Sigma_t = \kappa_2\,\Sigma_{t-1} + (1-\kappa_2)\,\hat{\varepsilon}_t\hat{\varepsilon}_t', \quad \hat{\varepsilon}_t = y_t - Z_t\beta_{t|t}. \tag{3.15}$$

Como a conectividade em cada instante t é computada a partir de $\beta_{t|t}$ e Σ_t, é κ_2 que determina a velocidade de reação do índice a um episódio de estresse; κ_1, por sua vez, diz respeito à estrutura de propagação, não à intensidade dos choques que se propagam.

A seleção de (κ_1, κ_2) é conduzida por verossimilhança preditiva fora da amostra, deixando os próprios dados escolherem o par. O filtro de Kalman produz, a cada instante t e condicional à informação disponível até $t-1$, a densidade preditiva

$$y_t \mid \mathcal{I}_{t-1} \sim N\big(Z_t\beta_{t|t-1},\; F_t\big), \quad F_t = Z_tP_{t|t-1}Z_t' + \Sigma_{t-1}, \tag{3.16}$$

avaliada no valor efetivamente observado, cuja log-verossimilhança no instante t é

$$\ell_t(\kappa_1,\kappa_2) = -\frac{1}{2}\left[N\log(2\pi) + \log|F_t| + e_t'F_t^{-1}e_t\right], \quad e_t = y_t - Z_t\beta_{t|t-1}. \tag{3.17}$$

Como e_t é construído com $\beta_{t|t-1}$, os coeficientes antes de o filtro observar y_t, a penalização por excesso de flexibilidade é automática e um κ_1 baixo permite que os coeficientes persigam ruído, e coeficientes que perseguem ruído preveem pior um passo à frente, reduzindo ℓ_t.

O procedimento de seleção segue quatro etapas. Primeiro, define-se uma grade $\kappa_1 \in \{0{,}94;\ 0{,}96;\ 0{,}98;\ 0{,}99;\ 0{,}995;\ 1{,}00\}$ e $\kappa_2 \in \{0{,}94;\ 0{,}96;\ 0{,}99\}$, incluindo valores baixos mesmo sabendo que tendem a perder. É a distância entre eles e o vencedor que sustenta a robustez da escolha. Segundo, estima-se um VAR(p) por MQO nas primeiras $t_0 = 200$ observações, usando as estimativas resultantes como β_0, P_0 (a covariância dos coeficientes) e Σ_0 (a covariância dos resíduos) para inicializar o filtro. Terceiro, o filtro é executado, para cada par da grade, ao longo da amostra completa, acumulando ℓ_t apenas para $t > t_0$ — o que torna o critério genuinamente fora da amostra, já que o período de inicialização não entra na soma $\mathcal{L}(\kappa_1,\kappa_2) = \sum_{t>t_0}\ell_t(\kappa_1,\kappa_2)$. Quarto, as somas são convertidas em pesos posteriores por

$$w(\kappa) \propto \exp\Big\{\mathcal{L}(\kappa) - \max_{\kappa'}\mathcal{L}(\kappa')\Big\}, \tag{3.18}$$

normalizados para somar um, com a subtração do máximo antes da exponenciação evitando estouro numérico. O par vencedor é aquele de maior peso posterior, restrito a $\kappa_1 < 1$. O pacote `ConnectednessApproach` exige esse parâmetro estritamente menor que um, já que $\kappa_1 = 1$ corresponde, por definição, ao caso degenerado de coeficientes constantes. O procedimento de seleção e a estimação final diferem em dois pontos. Primeiro em relação ao filtro, de maneira que a verossimilhança é calculada com uma implementação própria do filtro de Kalman, com

intercepto e com Σ_t atualizada pelo resíduo posterior aos coeficientes, enquanto o pacote `ConnectednessApproach` centra as séries na média, não tem intercepto e atualiza Σ_t pelo erro de previsão. Segundo, a seleção parte de um VAR(2) estimado nas primeiras $t_0 = 200$ observações, e o *prior* do modelo final usa a amostra completa, de modo que os primeiros períodos incorporam informação posterior a eles. Nenhuma das diferenças altera a conclusão. O par vencedor concentra peso posterior praticamente unitário, e o índice médio varia cerca de um ponto percentual entre os dois pares de maior verossimilhança (Apêndice **??**). O par selecionado é, por isso, adotado na estimação final. Os resultados completos da grade são reportados no Capítulo 4.

Regressão diádica

A hipótese de que o tipo de controle institucional organiza a topologia da rede (testada, na especificação original deste trabalho, por assortatividade nominal sobre o grafo completo) não se sustenta como formulada. A assortatividade nominal compara a fração de ligações que ocorrem dentro de categorias com a fração esperada sob distribuição aleatória, dadas as marginais. Em um grafo com apenas $N = 8$ nós e categorias de tamanho reduzido, essa fração é mecanicamente pequena mesmo quando a categoria não organiza nada, de modo que a estatística tende a um valor negativo por construção, um viés que a normalização usual da estatística, válida assintoticamente para grafos grandes, não corrige em amostras desse tamanho. Mais relevante ainda é que sem ponderação pelos pesos $\tilde{\theta}^{\tau}_{ij}$, a estatística conta cada aresta do grafo completo como igual às demais, de modo que seu valor depende apenas dos tamanhos dos grupos de cada categoria, não da intensidade real de *spillover* entre os bancos.

A alternativa adotada é um método de dados diádicos, no espírito de um modelo gravitacional onde a unidade de observação deixa de ser o banco e passa a ser o par ordenado (i, j), $i \neq j$. A matriz $\tilde{\Theta}^{\tau}$ tem $N(N-1)$ elementos fora da diagonal, cada um deles uma observação quanto o banco j explica da variância do erro de previsão do banco i. Estima-se, por Mínimos Quadrados Ordinários,

$$100\,\tilde{\theta}^{\tau}_{ij} = \mu + \alpha_j + \gamma_i + \beta\, D^{\text{ctrl}}_{ij} + \lambda\, D^{\text{vinc}}_{ij} + \delta\, D^{\text{porte}}_{ij} + \varepsilon_{ij}, \quad i \neq j, \tag{3.19}$$

em que α_j e γ_i são os efeitos fixos de emissor e de receptor. A indicadora D^{ctrl}_{ij} assume valor um quando os dois bancos do par têm a mesma natureza de controle, estatal ou privada. O vínculo societário é tratado separadamente, pela indicadora D^{vinc}_{ij}, igual a um para o único par da amostra ligado por controle acionário, BTG Pactual e Banco Pan, presente apenas no painel de extensão. D^{porte}_{ij} vale um quando ambos são instituições de grande porte. A separação distingue duas hipóteses que uma classificação única por categoria confundiria, a de que instituições de mesma natureza de controle compartilham volatilidade e a de que instituições com o mesmo controlador o fazem.

A Equação (3.19) é estimada tanto sobre o corte único do full sample estático quanto, para o par de instituições ligadas por controle societário efetivo presente no painel de extensão, sobre

uma sequência de cortes mensais extraídos da própria estimação TVP-VAR, o que permite avaliar se o sinal do efeito se repete ao longo do tempo e não apenas em uma estimativa pontual. Os resultados de ambas as estimações, incluindo a substituição de D_{ij}^{ctrl} por indicadoras específicas para cada par que compartilha categoria, são apresentados no Capítulo 4.

3.3 Visualização de Redes

A matriz normalizada $\tilde{\boldsymbol{\Theta}}^{\tau}$ define a matriz de adjacência de um grafo dirigido ponderado $G = (V, E, W)$, em que V representa as N instituições, E o conjunto de arestas de transmissão de variância e W os pesos $\tilde{\theta}_{ij}^{\tau}$. A convenção de direção é: $\tilde{\theta}_{ij}^{\tau}$ representa o fluxo de j para i (o choque em j explica parcela da variância do erro de previsão de i). Como o pacote `igraph` interpreta o elemento $\mathrm{mat}[i, j]$ como aresta saindo de i e chegando em j, a matriz é transposta antes da construção do grafo para preservar a semântica econômica.

Os índices definidos na Subseção 3.2 são mapeados em atributos visuais do grafo: (i) o tamanho do nó é proporcional ao índice TO_i; (ii) a cor do nó codifica o tipo de controle institucional de cada instituição; (iii) a espessura de cada aresta é proporcional ao *spillover* par-a-par NET_{ij}; e (iv) o sentido da seta indica a direção líquida do fluxo de risco entre os dois bancos, apontando do banco que transmite mais para o que transmite menos naquele par específico (Equação 3.11).

A rede DY é quase completa: com N, há até $N(N-1)$ arestas dirigidas (42 no painel principal e 56 no de extensão) nas métricas de centralidade calculadas sobre o grafo completo. Para fins de visualização exclusivamente, adota-se uma representação colapsada onde cada par não dirigido (i, j) é reduzido a uma única aresta líquida, cuja direção é dada pelo sinal de NET_{ij} (Equação 3.11). O grafo passa a ter no máximo $N(N-1)/2$ arestas líquidas (21 e 28, respectivamente). Sobre esse grafo colapsado, retêm-se apenas os pares cuja intensidade é de pelo menos 5% da intensidade do par mais forte observado naquela rede. Sobre esse grafo colapsado, retêm-se apenas os pares cuja intensidade é de pelo menos 5% da intensidade do par mais forte observado naquela rede. Esse filtro afeta exclusivamente a visualização e não a inferência conduzida a partir das tabelas e séries temporais dos índices DY e das métricas de centralidade, calculadas sobre o grafo completo, sem nenhum *threshold*.

O grafo do *full sample* é posicionado pelo algoritmo de Fruchterman-Reingold. Para os painéis comparativos entre subperíodos (pré-COVID, COVID-19, aperto da Selic e crise Americanas), as coordenadas dos nós são calculadas uma única vez sobre o *full sample* e mantidas fixas em todos os painéis. Essa escolha é metodológica, garantindo que as diferenças visuais entre painéis reflitam reconfiguração da topologia da rede, e não reposicionamento dos nós.

A representação em grafo é um instrumento heurístico e comunicativo. As escolhas de *threshold*, algoritmo de *layout* e paleta de cores afetam a percepção visual, mas não os coeficientes estimados. Toda a inferência sobre transmissão de risco entre as instituições é conduzida a partir

das tabelas e das séries temporais dos índices DY e das métricas de centralidade definidos na Subseção 3.2.

4 Resultados

4.1 Pré-tratamento dos dados

O painel principal reúne 2.234 pregões por instituição, de 02/10/2017 a 30/09/2026. O primeiro não tem fechamento anterior e, portanto, volatilidade estimada, de modo que o painel final tem 2.233 observações para as sete instituições (15.631 valores). A verificação de consistência do OHLC, com tolerância de 10^{-6}, e o filtro de liquidez não removem nenhum pregão. A regra de variância nula descrita na Metodologia trata 14 valores como ausentes (0,09%), no máximo seis por instituição, e esses são os únicos valores imputados pelo filtro de Kalman (Tabela 6).

Os retornos extremos ($|z| > 5$) somam 53 observações em 24 datas. Trinta e sete delas, em oito datas de março e abril de 2020, ocorrem em duas ou mais instituições no mesmo dia e são classificadas como eventos sistêmicos. As 16 restantes são casos isolados, com data e origem do evento na Tabela 7. Nenhuma é removida ou winsorizada.

Tabela 6 – Pré-tratamento por instituição (painel principal, N = 7)

Instituição	Abaixo do piso	Variância nula	Imputados	$\|z\| > 5$	Isolados
ITUB4	0	0	0	4	0
BBDC4	0	0	0	8	3
BBAS3	0	1	1	11	3
SANB11	0	3	3	7	1
BPAC11	0	1	1	10	5
BRSR6	0	3	3	8	4
ABCB4	0	6	6	5	0
Total	0	14	14	53	16

Fonte: elaboração própria. Painel de extensão (N = 8): [a acrescentar].

4.2 Propriedades das séries

Após a regra de variância nula, a curtose em excesso da log-volatilidade situa-se entre 1,8 e 4,2, e o menor valor de cada série está, no máximo, a 7,5 desvios-padrão da média, o de BPAC11 (Tabela 8).

O ADF, o DF-GLS, o Phillips-Perron e o Zivot-Andrews rejeitam a raiz unitária nas sete séries, e o KPSS rejeita a estacionariedade nas sete (Tabela 9). O Ljung-Box e o ARCH-LM rejeitam a ausência de autocorrelação e de heterocedasticidade condicional ($p < 0{,}0001$ em todas). O parâmetro de integração fracionária fica entre 0,47 (BPAC11) e 0,60 (BBAS3), com

Tabela 7 – Retornos extremos isolados ($|z| > 5$ em uma única instituição)

Banco	Data	Retorno (%)	Evento (fonte)	Tratamento
BRSR6	04/10/2017	−11,51	[fonte]	Mantido
BRSR6	08/10/2018	11,06	[fonte]	Mantido
BPAC11	23/08/2019	−16,48	[fonte]	Mantido
BPAC11	26/08/2019	−20,43	[fonte]	Mantido
BPAC11	27/08/2019	16,02	[fonte]	Mantido
BRSR6	10/03/2020	13,98	[fonte]	Mantido
BPAC11	11/03/2020	−14,34	[fonte]	Mantido
BPAC11	23/03/2020	−13,89	[fonte]	Mantido
BBAS3	24/04/2020	−14,35	[fonte]	Mantido
BBAS3	22/02/2021	−12,38	[fonte]	Mantido
BBDC4	09/11/2022	−19,10	[fonte]	Mantido
BBDC4	07/02/2024	−17,32	[fonte]	Mantido
BBDC4	08/05/2025	14,53	[fonte]	Mantido
BBAS3	16/05/2025	−13,57	[fonte]	Mantido
BRSR6	14/04/2026	−11,83	[fonte]	Mantido
SANB11	31/07/2026	12,53	[fonte]	Mantido

Fonte: elaboração própria. Retorno logarítmico diário, em pontos percentuais.

Tabela 8 – Estatísticas descritivas da log-volatilidade anualizada (N = 7)

Instituição	Média	DP	Mín.	Máx.	Assimetria	Curtose
ITUB4	−1,43	0,46	−3,18	1,03	0,37	1,77
BBDC4	−1,34	0,45	−2,93	1,28	0,59	2,25
BBAS3	−1,38	0,51	−3,58	1,37	0,50	2,07
SANB11	−1,36	0,48	−3,76	1,23	0,18	2,42
BPAC11	−1,09	0,51	−4,90	1,64	0,01	3,75
BRSR6	−1,33	0,48	−4,50	0,86	−0,34	4,16
ABCB4	−1,39	0,54	−4,73	1,05	−0,67	3,87

Fonte: elaboração própria. Curtose em excesso.

erro-padrão assintótico de 0,107. Cada estimativa difere de zero (estatística de 4,4 a 5,6) e de um (3,8 a 4,9), e todas estão a menos de um erro-padrão de 0,5, isto é, na fronteira entre a memória longa estacionária ($d < 0{,}5$) e a não estacionária ($d \geq 0{,}5$). As séries não são, portanto, nem $I(0)$ nem $I(1)$, o que reconcilia a rejeição simultânea do ADF e do KPSS e justifica a estimação do VAR em níveis (Subseção **??**).

A ordem do VAR é $p = 2$ pelo critério de Schwarz (BIC de $-13{,}536$), com margem de apenas 0,002 sobre $p = 1$; o AIC escolheria $p = 6$ e o HQ, $p = 3$. O VAR é estável (módulo máximo das raízes de 0,828), e o Apêndice **??** mostra que o ranking dos bancos não depende de p.

Tabela 9 – Testes de estacionariedade e parâmetro de memória longa (N = 7)

Instituição	ADF	KPSS (p)	DF-GLS	PP	ZA	$\hat{d}$
ITUB4	$-17{,}74$	$< 0{,}01$	$-10{,}00$	$-31{,}69$	$-12{,}32$	0,495
BBDC4	$-19{,}31$	$< 0{,}01$	$-5{,}88$	$-33{,}65$	$-13{,}17$	0,528
BBAS3	$-17{,}82$	$< 0{,}01$	$-2{,}40$	$-30{,}60$	$-12{,}16$	0,599
SANB11	$-19{,}74$	$< 0{,}01$	$-9{,}31$	$-34{,}01$	$-13{,}23$	0,483
BPAC11	$-19{,}26$	$< 0{,}01$	$-10{,}48$	$-34{,}37$	$-13{,}23$	0,474
BRSR6	$-22{,}88$	$< 0{,}01$	$-12{,}37$	$-37{,}15$	$-14{,}61$	0,539
ABCB4	$-20{,}97$	$< 0{,}01$	$-9{,}76$	$-35{,}40$	$-15{,}57$	0,589

Fonte: elaboração própria. Valores críticos a 5%: ADF $-2{,}86$; DF-GLS $-1{,}94$; PP $-2{,}86$; ZA $-5{,}08$. O KPSS reporta o limite inferior do p-valor. Erro-padrão assintótico de $\hat{d}$: 0,107.

4.3 Seleção dos fatores de esquecimento

A Tabela 10 reporta a log-verossimilhança preditiva de cada par (κ_1, κ_2). O par selecionado é $(0{,}995;\ 0{,}99)$, com peso posterior igual a 1. A folga é grande: o segundo melhor par, $(1{,}00;\ 0{,}99)$, que corresponde a coeficientes constantes, fica 121,5 pontos abaixo, e o melhor par estimável pelo pacote entre os demais, $(0{,}99;\ 0{,}99)$, 219,1 pontos abaixo. A variação temporal dos coeficientes melhora, portanto, a previsão um passo à frente, ainda que $\kappa_1 = 0{,}995$ implique uma memória de cerca de 200 observações, bem mais lenta que a da covariância ($\kappa_2 = 0{,}99$, cerca de 100 observações).

[**Se a grade estendida mantiver o vencedor:** O ótimo é interior nas duas dimensões da grade.] [**Se não estender:** O ótimo é interior em κ_1, mas está no limite superior da grade em κ_2, de modo que um valor maior de κ_2 poderia ajustar melhor.]

Tabela 10 – Log-verossimilhança preditiva por par (κ_1, κ_2)

	$\kappa_2 = 0{,}94$	$\kappa_2 = 0{,}96$	$\kappa_2 = 0{,}99$
$\kappa_1 = 0{,}94$	-19.080	-15.885	-12.370
$\kappa_1 = 0{,}96$	-13.830	-11.723	-9.321
$\kappa_1 = 0{,}98$	-9.929	-8.671	-7.163
$\kappa_1 = 0{,}99$	-8.445	-7.528	-6.410
$\kappa_1 = 0{,}995$	-7.890	-7.125	$\mathbf{-6.191}$
$\kappa_1 = 1{,}00$	-7.694	-7.060	-6.312

Fonte: elaboração própria. Soma de ℓ_t para $t > t_0 = 200$. Em negrito, o par selecionado.

4.4 Conectividade estática do painel principal

Com $p = 2$ e $\tau = 10$, o índice de conectividade total da amostra completa é de 52,9%. Como o nível do índice depende do número de instituições, não é comparado ao de outros estudos (Seção 3.2).

A Tabela 11 reúne TO, FROM e NET e o confronto com a segmentação do Banco Central, ordenado pelo TO. Os cinco primeiros do ranking de transmissão são exatamente os cinco bancos do S1; o ABC Brasil (S3) vem em sexto e o Banrisul (S2), em sétimo. O Itaú é o maior transmissor líquido ($+19{,}3$), seguido por Bradesco ($+8{,}9$) e Banco do Brasil ($+2{,}8$). Santander e BTG, ambos do S1, são receptores líquidos ($-2{,}0$ e $-5{,}0$), e os maiores receptores são Banrisul ($-14{,}9$) e ABC Brasil ($-9{,}2$). O TO varia de 28,6 a 81,0 e o FROM, de 43,4 a 61,7: o ranking é determinado pela transmissão. O par mais intenso é Itaú-Bradesco: 18,5% da variância do Itaú vem do Bradesco e 19,7% da do Bradesco vem do Itaú. O Itaú é o maior transmissor líquido nas 13 especificações de robustez, e o Banrisul, o maior receptor em 12 delas (Apêndice **??**).

Tabela 11 – Conectividade direcional e segmentação prudencial (painel principal)

Instituição	TO	FROM	NET	Segmento BCB	Posto (TO)
ITUB4	80,96	61,70	19,26	S1	1
BBDC4	69,34	60,47	8,87	S1	2
BBAS3	59,52	56,67	2,84	S1	3
SANB11	52,32	54,34	$-2{,}01$	S1	4
BPAC11	42,43	47,40	$-4{,}96$	S1	5
ABCB4	36,85	46,00	$-9{,}15$	S3	6
BRSR6	28,59	43,44	$-14{,}85$	S2	7

Fonte: elaboração própria. Segmentos conforme a Resolução CMN nº 4.553/2017.

As métricas recursivas ordenam os bancos como o FROM [e o TO no grafo invertido; correlação de postos de Spearman igual a 1, a confirmar com o `spearman_centralidade.csv`], como discutido na Metodologia.

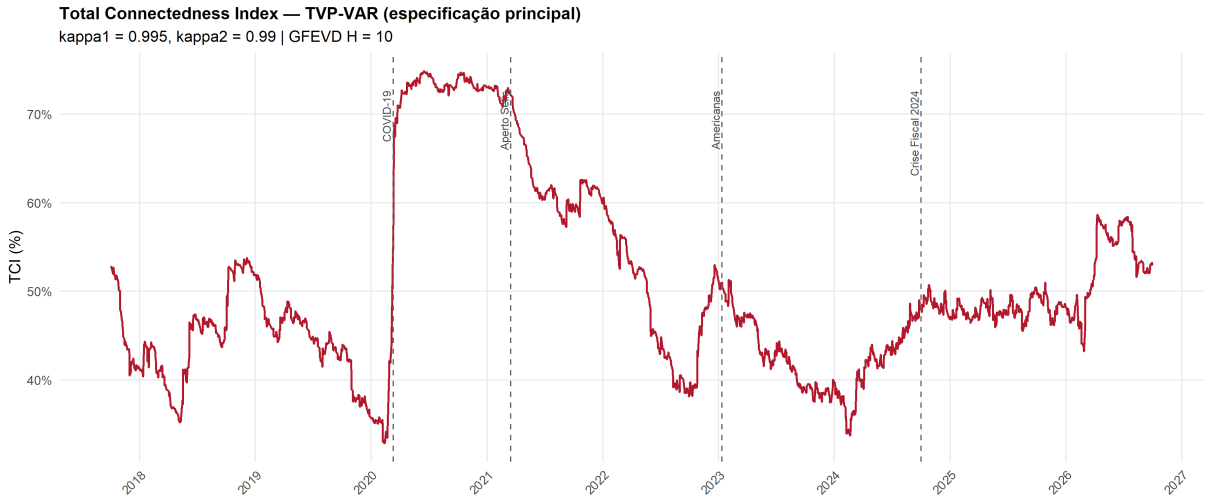
4.5 Conectividade dinâmica

A Figura 2 mostra o TCI do TVP-VAR. [As primeiras 200 observações, usadas como treino, não são mostradas: o *prior* usa a amostra completa, e o índice inicial coincide com o estático.] Entre 2019 e fevereiro de 2020, o índice oscila em torno de 43,1%, com mínimo de 32,9% em 13/02/2020. A pandemia inaugura um regime distinto: o TCI vai de 46,0% em 06/03/2020 para 53,1% em 09/03, 63,8% em 12/03 e 68,2% em 13/03, e supera 70% a partir de 24/03. Ele não volta a cair em seguida: de abril de 2020 a meados de março de 2021 permanece entre 70,8% e 74,9% (média de 73,2%), com máximo de 74,9% em 16/06/2020, cerca de 30 pontos percentuais acima do nível anterior. O declínio é gradual, com o índice abaixo de 60% só em 10/08/2021 e abaixo de 50% em 20/05/2022, e a mínima de 33,7% em 20/02/2024.

Os demais episódios são de outra ordem. O início do aperto monetário, em 17/03/2021, não coincide com uma elevação: o TCI está em 72,1% nessa data e desce para 60,7% em junho. O episódio Americanas é precedido por uma subida que começa antes dele: o índice vai de

38,1% em 30/09/2022 a 53,0% em 20/12/2022 e está em 51,0% em 12/01/2023. Em outubro de 2024, o TCI está em 47,9%, a mesma faixa dos 15 meses seguintes (média de 48,1%), depois de ter subido de 33,7% em fevereiro do mesmo ano. A única elevação posterior à pandemia com magnitude comparável é a de 2026: o índice parte de 43,3% em 27/02, atinge 58,7% em 10/04, permanece acima de 55% até 31/07 e termina a amostra em 53,3%. A média de abril a julho (56,8%) supera em cerca de 9 pontos percentuais a de 2025 (48,0%), mas fica 16 pontos abaixo do pico de 2020. A hipótese de elevação em períodos de instabilidade se sustenta, assim, com clareza para a pandemia e, em menor grau, para 2022–2023 e 2026, mas não para o aperto da Selic nem para o estresse fiscal de 2024.

Figura 2 – Índice de conectividade total: TVP-VAR

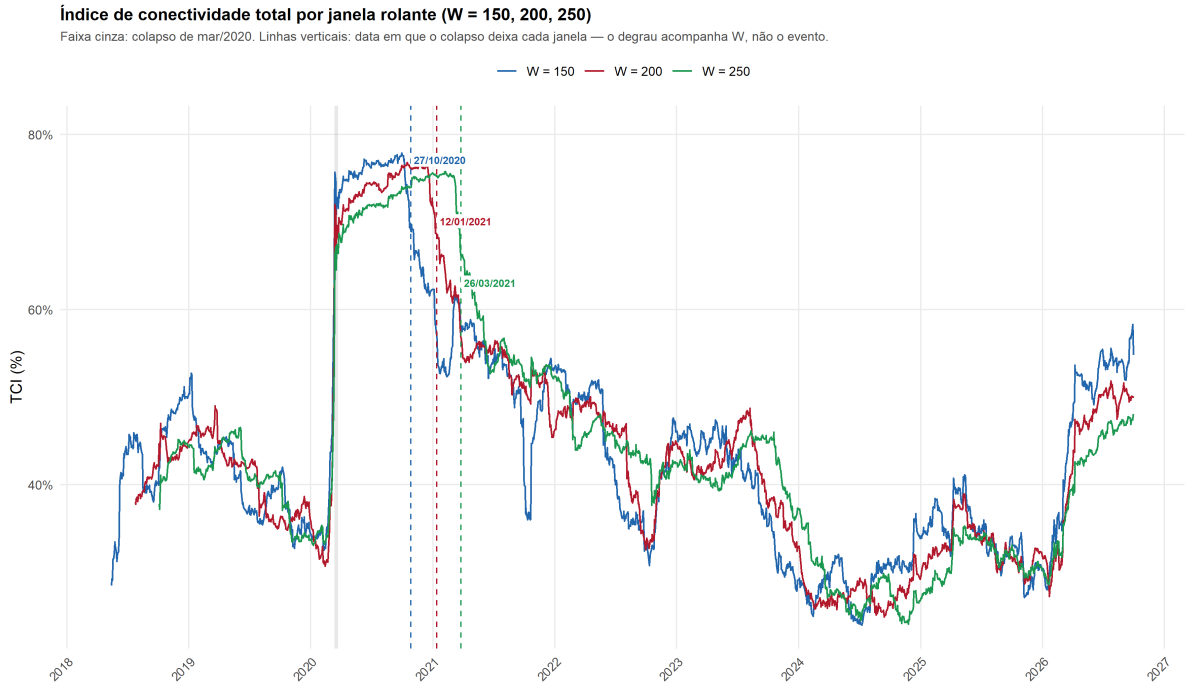


Fonte: elaboração própria. $\kappa_1 = 0{,}995$, $\kappa_2 = 0{,}99$, $\tau = 10$. Linhas tracejadas: eventos da Tabela 5.

A Janela rolante

A Figura 3 compara o TCI estimado por janela rolante com $W = 150$, 200 e 250. O pico do período da pandemia é datado em 30/09/2020 (77,9%), 16/10/2020 (76,8%) e 08/02/2021 (75,8%), respectivamente, ou seja, desloca-se 131 dias com a largura da janela, enquanto o do TVP-VAR é de 16/06/2020. O índice cai de 6,3 a 6,9 pontos percentuais nos 20 pregões em torno das datas em que o colapso de março sai de cada janela (27/10/2020, 12/01/2021 e 26/03/2021), e passa a menos de 60% em 06/01/2021, 22/03/2021 e 12/05/2021, contra 10/08/2021 no TVP-VAR. O nível e a dispersão são parecidos (TCI médio de 44,1%, 44,0% e 44,2%; desvio-padrão de 12,9 a 13,7), e as séries são correlacionadas (0,95 entre 150 e 200, 0,90 entre 150 e 250 e 0,96 entre 200 e 250), mas o degrau acompanha W, e não o evento. O episódio de 2026 também depende de W: o máximo é de 58,3% em 28/09/2026 com $W = 150$, de 51,8% em 24/07/2026 com $W = 200$ e de 48,1% em 30/09/2026 com $W = 250$. Por isso a janela rolante não é usada como especificação principal.

Figura 3 – Índice de conectividade total por janela rolante



Fonte: elaboração própria. Linhas verticais: data em que o colapso de março de 2020 sai de cada janela.

Referências

ACEMOGLU, Daron; OZDAGLAR, Asuman; TAHBAZ-SALEHI, Alireza. Systemic Risk and Stability in Financial Networks. **American Economic Review**, v. 105, n. 2, p. 564–608, fev. 2015. ISSN 0002-8282. DOI: 10.1257/aer.20130456. Acesso em: 26 abr. 2026.

ALLEN, Franklin; GALE, Douglas. Financial Contagion. **The Journal of Political Economy**, v. 108, n. 1, p. 1–33, 2000. JSTOR: 3038241.

ALLEN, Franklin; GALE, Douglas. Optimal Financial Crises. **The Journal of Finance**, [American Finance Association, Wiley], v. 53, n. 4, p. 1245–1284, 1998. ISSN 0022-1082. JSTOR: 117401. Acesso em: 26 abr. 2026.

ANDERSEN, Torben G.; BOLLERSLEV, Tim; DIEBOLD, Francis X.; EBENS, Heiko. The Distribution of Realized Stock Return Volatility. **Journal of Financial Economics**, v. 61, n. 1, p. 43–76, jul. 2001. ISSN 0304-405X. DOI: 10.1016/S0304-405X(01)00055-1. Acesso em: 12 jun. 2026.

ANDERSEN, Torben G.; BOLLERSLEV, Tim; DIEBOLD, Francis X.; LABYS, Paul. Modeling and Forecasting Realized Volatility. **Econometrica**, [Wiley, Econometric Society], v. 71, n. 2, p. 579–625, 2003. ISSN 0012-9682. JSTOR: 3082068. Acesso em: 12 jun. 2026.

ANDO, Tomohiro; GREENWOOD-NIMMO, Matthew; SHIN, Yongcheol. Quantile Connectedness: Modeling Tail Behavior in the Topology of Financial Networks. **Management Science**, INFORMS, v. 68, n. 4, p. 2401–2431, 2022. Acesso em: 17 jun. 2026.

ANTONAKAKIS, Nikolaos; CHATZIANTONIOU, Ioannis; GABAUER, David. Refined Measures of Dynamic Connectedness Based on Time-Varying Parameter Vector Autoregressions. **Journal of Risk and Financial Management**, Multidisciplinary Digital Publishing Institute, v. 13, n. 4, p. 84, abr. 2020. ISSN 1911-8074. DOI: 10.3390/jrfm13040084. Acesso em: 16 maio 2026.

BARUNÍK, Jozef; KŘEHLÍK, Tomáš. Measuring the Frequency Dynamics of Financial Connectedness and Systemic Risk. **Journal of Financial Econometrics**, Oxford University Press, v. 16, n. 2, p. 271–296, 2018. Acesso em: 17 jun. 2026.

BOSTANCI, Gorkem; YILMAZ, Kamil. How Connected Is the Global Sovereign Credit Risk Network? **Journal of Banking & Finance**, Elsevier, v. 113, 105761, 2020. DOI: 10.1016/j.jbankfin.2020.105761. Acesso em: 21 maio 2026.

CAJUEIRO, Daniel O.; TABAK, Benjamin M. The Role of Banks in the Brazilian Interbank Market: Does Bank Type Matter? **Physica A Statistical Mechanics and its Applications**, Elsevier, v. 387, p. 6825–6836, dez. 2008. ISSN 0378-4371. DOI: 10.1016/j.physa.2008.08.031. Acesso em: 16 maio 2026.

CHATZIANTONIOU, Ioannis; GABAUER, David. EMU Risk-Synchronisation and Financial Fragility through the Prism of Dynamic Connectedness. **The Quarterly Review of Economics and Finance**, v. 79, p. 1–14, fev. 2021. ISSN 1062-9769. DOI: 10.1016/j.qref.2020.12.003. Acesso em: 16 maio 2026.

CONSELHO MONETÁRIO NACIONAL. **Resolução CMN N° 4.958, de 21 de Outubro de 2021**. [*S. l.: s. n.*], out. 2021.

CONSELHO MONETÁRIO NACIONAL. **Resolução CMN Nº 4.553, de 30 de Janeiro de 2017**. [*S. l.: s. n.*], jan. 2017.

CONT, Rama; MOUSSA, Amal; SANTOS, Edson B. Network Structure and Systemic Risk in Banking Systems. *In:* FOUQUE, Jean-Pierre; LANGSAM, Joseph A. (ed.). **Handbook on Systemic Risk**. 1. ed. [*S. l.*]: Cambridge University Press, maio 2013. p. 327–368. ISBN 978-1-107-02343-7 978-1-139-15118-4. DOI: 10.1017/CBO9781139151184.018. Acesso em: 22 abr. 2026.

DEL NEGRO, Marco; PRIMICERI, Giorgio E. Time Varying Structural Vector Autoregressions and Monetary Policy: A Corrigendum. **The Review of Economic Studies**, Review of Economic Studies Ltd, v. 82, n. 4, p. 1342–1345, 2015. Acesso em: 21 set. 2026.

DEMIRER, Mert *et al.* Estimating Global Bank Network Connectedness. **Journal of Applied Econometrics**, v. 33, n. 1, p. 1–15, jan. 2018. ISSN 0883-7252, 1099-1255. DOI: 10.1002/jae.2585. Acesso em: 27 maio 2026.

DIAMOND, Douglas W.; DYBVIG, Philip H. Bank Runs, Deposit Insurance, and Liquidity. **Journal of Political Economy**, University of Chicago Press, v. 91, n. 3, p. 401–419, 1983. Acesso em: 26 abr. 2026.

DIEBOLD, Francis X.; INOUE, Atsushi. Long Memory and Regime Switching. **Journal of Econometrics**, v. 105, n. 1, p. 131–159, nov. 2001. ISSN 0304-4076. DOI: 10.1016/S0304-4076(01)00073-2. Acesso em: 12 jun. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Better to Give than to Receive: Predictive Directional Measurement of Volatility Spillovers. **International Journal of Forecasting**, v. 28, n. 1, p. 57–66, jan. 2012. ISSN 0169-2070. DOI: 10.1016/j.ijforecast.2011.02.006. Acesso em: 22 abr. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Equity Market Spillovers in the Americas. **Central Banking, Analysis, and Economic Policies Book Series**, Central Bank of Chile, v. 15, p. 199–214, 2011. Acesso em: 18 out. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Measuring Financial Asset Return and Volatility Spillovers, With Application to Global Equity Markets. **Economic Journal**, v. 119, p. 158–171, jan. 2009. DOI: 10.1111/j.1468-0297.2008.02208.x.

DIEBOLD, Francis X.; YILMAZ, Kamil. On the Network Topology of Variance Decompositions: Measuring the Connectedness of Financial Firms. **Journal of Econometrics**, v. 182, n. 1, p. 119–134, set. 2014. ISSN 0304-4076. DOI: 10.1016/j.jeconom.2014.04.012. Acesso em: 22 abr. 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. **On the Past, Present, and Future of the Diebold-Yilmaz Approach to Dynamic Network Connectedness**. [*S. l.*]: arXiv, jan. 2023. DOI: 10.48550/arXiv.2211.04184. arXiv: 2211.04184 [econ.EM]. Acesso em: 20 maio 2026.

DIEBOLD, Francis X.; YILMAZ, Kamil. Trans-Atlantic Equity Volatility Connectedness: U.S. and European Financial Institutions, 2004–2014. **Journal of Financial Econometrics**, Oxford University Press, v. 14, n. 1, p. 81–127, 2016. Acesso em: 26 abr. 2026.

GABAUER, David. **ConnectednessApproach: Connectedness Approach**. [*S. l.*]: Comprehensive R Archive Network, mar. 2022. p. 1.0.4. DOI: 10.32614/CRAN.package.ConnectednessApproach. Acesso em: 26 maio 2026.

GEWEKE, John; PORTER-HUDAK, Susan. The Estimation and Application of Long Memory Time Series Models. **Journal of Time Series Analysis**, John Wiley & Sons, Ltd, v. 4, n. 4, p. 221–238, jul. 1983. ISSN 1467-9892. DOI: 10.1111/j.1467-9892.1983.tb00371.x. Acesso em: 18 out. 2026.

GLASSERMAN, Paul; YOUNG, H. Peyton. Contagion in Financial Networks. **Journal of Economic Literature**, v. 54, n. 3, p. 779–831, set. 2016. ISSN 0022-0515. DOI: 10.1257/jel.20151228. Acesso em: 22 abr. 2026.

GLASSERMAN, Paul; YOUNG, H. Peyton. How Likely Is Contagion in Financial Networks? **Journal of Banking & Finance**, v. 50, p. 383–399, jan. 2015. ISSN 0378-4266. DOI: 10.1016/j.jbankfin.2014.02.006. Acesso em: 22 abr. 2026.

KOOP, Gary; KOROBILIS, Dimitris. Large Time-Varying Parameter VARs. **Journal of Econometrics**, v. 177, n. 2, p. 185–198, dez. 2013. ISSN 03044076. DOI: 10.1016/j.jeconom.2013.04.007. Acesso em: 21 set. 2026.

KOOP, Gary; PESARAN, M. Hashem; POTTER, Simon M. Impulse Response Analysis in Nonlinear Multivariate Models. **Journal of Econometrics**, v. 74, n. 1, p. 119–147, set. 1996. ISSN 0304-4076. DOI: 10.1016/0304-4076(95)01753-4. Acesso em: 8 maio 2026.

MORITZ, Steffen; BARTZ-BEIELSTEIN, Thomas. imputeTS: Time Series Missing Value Imputation in R. **The R Journal**, v. 9, n. 1, p. 207, 2017. ISSN 2073-4859. DOI: 10.32614/RJ-2017-009. Acesso em: 26 maio 2026.

MOURA, Bruna Gonçalves Fonseca; FERREIRA, Bruno Pérez; CORRÊA, Ana Carolina Costa. Brazilian Banks Risk-Taking and Systemic Risk. **The Quarterly Review of Economics and**

Finance, Elsevier, v. 98, n. 100, 101913, 2024. DOI: 10.1016/j.qref.2024.101913. Acesso em: 26 abr. 2026.

PESARAN, H.Hashem; SHIN, Yongcheol. Generalized Impulse Response Analysis in Linear Multivariate Models. **Economics Letters**, v. 58, n. 1, p. 17–29, jan. 1998. ISSN 01651765. DOI: 10.1016/S0165-1765(97)00214-0. Acesso em: 22 abr. 2026.

PRIMICERI, Giorgio E. Time Varying Structural Vector Autoregressions and Monetary Policy. **The Review of Economic Studies**, Review of Economic Studies Ltd, v. 72, n. 3, p. 821–852, 2005. Acesso em: 21 set. 2026.

ROGERS, L. C. G.; SATCHELL, S. E. Estimating Variance From High, Low and Closing Prices. **The Annals of Applied Probability**, Institute of Mathematical Statistics, v. 1, n. 4, p. 504–512, 1991. ISSN 1050-5164. JSTOR: 2959703. Acesso em: 18 set. 2026.

SILVA, Mairton Nogueira; PASSOS, Marcelo De Oliveira *et al.* Dynamic Connectivity and Contagion Risk Among Bank Stocks in Brazil. **Computational Economics**, Springer & Society for Computational Economics, v. 66, n. 2, p. 1513–1543, 2025. Acesso em: 26 abr. 2026.

SILVA, Thiago Christiano; DE SOUZA, Sergio Rubens Stancato; TABAK, Benjamin Miranda. Network Structure Analysis of the Brazilian Interbank Market. **Emerging Markets Review**, v. 26, p. 130–152, mar. 2016. ISSN 15660141. DOI: 10.1016/j.ememar.2015.12.004. Acesso em: 22 abr. 2026.

SILVA, Walmir; KIMURA, Herbert; SOBREIRO, Vinicius Amorim. An Analysis of the Literature on Systemic Financial Risk: A Survey. **Journal of Financial Stability**, v. 28, p. 91–114, fev. 2017. ISSN 1572-3089. DOI: 10.1016/j.jfs.2016.12.004. Acesso em: 22 abr. 2026.

YANG, Dennis; ZHANG, Qiang. Drift-Independent Volatility Estimation Based on High, Low, Open, and Close Prices. **The Journal of Business**, University of Chicago Press, v. 73, n. 3, p. 477–91, 2000. DOI: 10.1086/209650. Acesso em: 7 maio 2026.